

序列比对

1. 序列比对的基本概念

生物序列一般指**DNA**、**RNA**或者蛋白质字符形成的特定顺序。比较不同类型的生物体序列的相互关系是生物信息分析的核心问题。

私は富士太郎です。

この川は黄河です。

字母表和序列

- 字母表

- 4字符DNA字母表: {A, C, G, T}
- 扩展的遗传学字母表或IUPAC编码
- 单字母氨基酸编码

IUPAC碱基代码表

代码	英文含义	中文含义
G	Guanine	鸟嘌呤
A	Adenine	腺嘌呤
T (U)	Thymine (Uracil)	胸腺嘧啶 (尿嘧啶)
C	Cytosine	胞嘧啶
R (A or G)	PuRine	嘌呤
Y (C or T or U)	Pyrimidine	嘧啶
M (A or C)	Amino	腺嘌呤或胞嘧啶(氨基)
K (G or T)	Ketone	鸟嘌呤或胸腺嘧啶(酮基)
S (C or G)	Strong interaction	强相互作用碱基
W (A or T)	Weak interaction	弱相互作用碱基
H (A or C or T)	Not-G (H after G)	非鸟嘌呤
B (C or G or T)	Not-A (B after A)	非腺嘌呤
V (A or C or G)	Not-T/U (V after U)	非胸腺嘧啶
D (A or G or T)	Not-C (D after C)	非胞嘧啶
N (A or C or G or T)	Any	不确定

核酸序列

- >JN900492.1 Homo sapiens tumor suppressor **TP53 (TP53) mRNA**, complete cds, alternatively spliced
- GGT TTT CCC CTCC CATGTGCTCAAGACTGGCGCTAAAAGTTTTGAGCTTCTCAAAGTCTAGAGCCACC
GTCCAGGGAGCAGGTAGCTGCTGGGCTCCGGGGACACTTTGCGTTCGGGCTGGGAGCGTGCTTTCCA
CGACGGTGACACGCTTCCCTGGATTGGCAGCCAGACTGCCTTCCGGGTCACTGCCATGGAGGAGCCGC
AGTCAGATCCTAGCGTCGAGCCCCCTCTGAGTCAGGAAACATTTTCAGACCTATGGAAACTGTGAGTGG
ATCCATTGGAAGGGCAGGCCCACCAACCCCAACCCAGCCCCCTAGCAGAGACCTGTGGGAAG
CGAAAATTCCATGGGACTGACTTTCTGCTCTTGTCTTTCAGACTTCCTGAAAACAACGTTCTGTCCCCCT
TGCCGTCCCAAGCAATGGATGATTTGATGCTGTCCCCGGACGATATTGAACAATGGTTCACTGAAGACC
CAGGTCCAGATGAAGCTCCCAGAATGCCAGAGGCTGCTCCCCCGTGGCCCCCTGCACCAGCAGCTCCT
ACACCGGCGGCCCCCTGCACCAGCCCCCTCCTGGCCCCCTGTCATCTTCTGTCCCTTCCCAGAAAACCTACC
AGGGCAGCTACGGTTTCCGTCTGGGCTTCTTGCACTTCTGGGACAGCCAAGTCTGGCGTGATCTTGGCTT
ACTGCAGCCTTTGCCTCCCCGGCTCGAGCAGTCCTGCCTCAGCCTCCGGAGTAGCTGGGACCACAGGT
TCATGCCACCATGGCCAGCCAACCTTTTGCATGTTTTGTAGAGATGGGGTCTCACAGTGTTGCCCAGGCT
GGTCTCAAACCTCCTGGGCTCAGGCGATCCACCTGTCTCAGCCTCCCAGAGTGCTGGGATTACAATTGTG
AGCCACCACGTCCAGCTGGAAGGGTCAACATCTTTTACATTCTGCAAGCACATCTGCATTTTACCCCCAC
CCTTCCCCTCCTTCTCCCTTTTTATATCCCATTTTTATATCGATCTCTTATTTACAATAAACTTTGCTGCCA
CCTGTGTGTCTGAGGGGTG

IUPAC氨基酸代码表


A	alanine	P	proline
B	aspartate or asparagines	Q	glutamine
C	cystine	R	arginine
D	aspartate	S	serine
E	glutamate	T	threonine
F	phenylalanine	U	selenocysteine
G	glycine	V	valine
H	histidine	W	tryptophan
I	isoleucine	Y	tyrosine
K	lysine	Z	glutamate or glutamine
L	leucine	X	any
M	methionine	*	translation stop
N	asparagine	-	gap of indeterminate length

氨基酸序列


>sp|P04637|P53_HUMAN Cellular tumor antigen **p53** OS=Homo sapiens OX=9606 GN=TP53
PE=1 SV=4

MEEPQSDPSVEPPLSQETFSDLWKLLPENNVLSPLPSQAMDDLMLSPDDIEQWFTEDPGP
DEAPRMPEAAPPVAPAPAAPTPAAPAPAPSWPLSSSVPSQKTYQGSYGFRLGFLHSGTAK
SVTCTYSPALNKMFCQLAKTCPVQLWVDSTPPPGTRVRAMAIYKQSQHMTEVVRRCPHHE
RCSDSDGLAPPQHLIRVEGNLRVEYLDDRNTFRHSVVVPYEPPEVGSDCTTIHYNMYMCNS
SCMGGMNRRPILTIITLEDSSGNLLGRNSFEVRVCACPGRDRRTEENLRKKGEPHHELP
PGSTKRALPNNTSSSPQPKKKPLDGEYFTLQIRGRERFEMFRELNEALELKDAQAGKEPG
GSRAHSSHLKSKKGQSTSRHKKLMFKTEGPDSD

比较发现相似之处



比较发现相似之处



生物序列之间的相互关系： ——序列比对的理论基础

同源性(homology):

是指序列们是由共同祖先进化而来，讲两条序列的同源关系，只有两种情况：**同源、不同源**。

相似性： 指序列间的差别，是一个度量。

同源与相似的关系：

- 同源序列一般是相似的
- 相似序列不一定是同源的
- 进化趋同（同功能）

◆ Ortholog (直系同源):

两个基因通过 物种形成 的事件而产生，或源于不同物种的具有共同祖先的两个基因，或者两个物种中的同一基因，一般具有相同的功能。

◆ Paralog (旁系同源):


指相同的基因组内因 基因复制 形成的多个具有不同功能的基因。

◆ Xenolog (异同源):

由某一个 水平基因转移 事件而得到的同源序列。

◆ Convergence(趋同):

序列的相似性是由 随机因素 产生。



序列比对的概念

◆ **序列比对**：通过比较生物分子序列，发现它们的相似性，找出序列之间共同的区域，同时辨别序列之间的差异。

◆ **序列的两两比对**（**Pairwise Sequence Alignment**）：

具体操作是：两个序列写成两行，

相同或者相似的字符置于**同一列**，
不同的字符要么置于同一列作为一个**错配**，
要么对应于另一个序列上一个**空位**。

序列两两比对示例

TT TGTGTGCATTTAAGGGTGATAGTGTATTTGCTCTTTAAGAGCTG

|| || || | | ||| | |||| ||||| ||| |||

TTGACAGGTACCCAACCTGTGTGTGCTGATGTA . TTGCTGGCCAAGGACTG

AGTGTTTGAGCCTCTGTTTGTGTGTAATTGAGTGTGCATGTGTGGGAGTG

| | | | ||||| | |||| | || | |

AAGGATC TCAGTAATTAATCATGCACCTATGTGGCGG


AAATTGTGGAATGTGTATGCTCATAGCACTGAGTGAAAATAAAAGATTGT

||| | ||| || || ||| | ||||| || ||||| |

AAA . TATGGGATATGCATGTCGA . . . CACTGAGTG . . AAGGCAAGATTAT

序列两两比对

两个序列间保持顺序(或拓扑结构)的元素对应关系



序列比对的作用和意义

序列比对是生物信息学中**最基本、最重要**的操作，通过序列比较可以发现生物序列中的**功能、结构和进化**的信息。

1. 用于系统发育分析 (phylogenetic analysis)

通过序列比对，可以寻找序列间的同源性(相似性)，这种同源相似性是序列间进化关系的一种反映，所构建的数据矩阵成为系统发育分析的基础。

2. 结构预测 (structure prediction)

将新序列与已知结构的蛋白质序列进行比对，可以通过序列同源性来粗略地推测其结构的相似性。



3. 序列基序鉴定 (sequence motif identification)

局部排列可以鉴定蛋白质和核苷酸序列中潜在的序列和功能基序。

4. 功能预测 (function prediction)

蛋白质序列间的高度相似性通常意味着同源序列间的功能相似性。

5. 数据库搜索(database search)

Basic Local Alignment Search Tool

BLAST finds regions of similarity between biological sequences. The program compares nucleotide or protein sequences to sequence databases and calculates the statistical significance.

[Learn more](#)

NEWS



A new version **IgBLAST (1.13)** is here.

Your tool to facilitate the analysis of immunoglobulin and T cell receptor variable domain sequences.

Fri, 08 Mar 2019 17:00:00 EST

[More BLAST news...](#)

Web BLAST




sp|P04637|P53_HUMAN Cellular tumor antigen p53 OS=Homo sapiens
NP_001315517.1 cellular tumor antigen p53 isoform 4 [Danio rerio]

[Search](#)[Human](#)[Mouse](#)[Rat](#)[Microbes](#)

Accession	Description	Links
☒ lc Query_229799	sp P04637 P53_HUMAN Cellular tumor antigen p53 OS=Homo sapiens OX=9606 GN=TP53 PE=1 SV=4	
☒ lc Query_229801	NP_001315517.1 cellular tumor antigen p53 isoform 4 [Danio rerio]	

▼ Graphical Overview



▼ Alignments ☒ Select All [Re-align](#) [Mouse over the sequence identifier for sequence title](#)


View Format: **Compact** Conservation Setting: **2 Bits**

☒ Query_229799	1	MEEPQSDPSVEPLSQETFSDLWKLLENVLSPLSQAMDDLMLSPDDIEQWFTEDPGPDEAPRMP EAAPP VAPAP AAP	80
☒ Query_229801		-----	
☒ Query_229799	81	TPAAPAP APSWFLSSSVFSQKTYQGSYGFRLGFLHSGTAKSVTCTYSPALNKMFCQLAKTCPVQLWVDSTPPGTRVRAM	160
☒ Query_229801	1	-----MVVDVAPPQGSVVRAT	16
☒ Query_229799	161	AIYKQSQHMTVEVVRCPHGERCSDSGLAPPQHILIRVEGNLRVEYLD DRNTFRHSVVVPYEPPEVGS DCTTIHYNMNCNS	240
☒ Query_229801	17	AIYKKSEHVAEVVRCPHGERPDGDNLAPAGHLIRVEGNQRANYREDNITLRHSVTFPYEAPQLGAEWTTVLLNYMNCNS	96
☒ Query_229799	241	SCMGGMNRRPILTIITLEDSSGNLLGRNSFEVRVCACFGRDRRTEENLRKKGEPHHELPPGS-TKRALPNTSSSP---	316
☒ Query_229801	97	SCMGGMNRRPILTIITLETQEGQLGRRSFEVRVCACFGRDRKTEESNFKKDQETKTMAKTTTGTKRSLVKESSATLRP	176
☒ Query_229799	317	---QPKKKPL-DGEYFTLQIRGRERFEMFRELNEALELKDAQAGKEP GGSRAHSSHLKSKKGQSTS---RHKKLMFKTEG	389
☒ Query_229801	177	EGSKKAKGSSDEEIFTLQVRGRERYELKKLNDLSLELSDVVPASDAEKYRQKFWTKNKKENRESSEPKQGGKLMVKDEG	256
☒ Query_229799	390	-PDS	393
☒ Query_229801	257	RS	261

Graphic Summar


Distribution of the top 1 Blast Hits on 1 subject sequences

Mouse over to see the title, click to show alignments



Dot Matrix View

Plot of lcl|Query_229799 vs lcl|Query_229801



序列比对的原理和算法

◆ 打分功能: 度量元素间 (nucleotides, amino acids, gaps) 相似度的尺度


点阵分析方法, 打分矩阵

◆ 比对算法

动态规划算法

Needleman-Wunsch 算法,

Smith-Waterman 算法




Match (.)

Mismatch
(substitution)

Graphic Summar


Distribution of the top 1 Blast Hits on 1 subject sequences

Mouse over to see the title, click to show alignments



Dot Matrix View

Plot of lcl|Query_229799 vs lcl|Query_229801



处


轴

点阵表

	A	T	G	C	T	C	A	T	G
A	1	0	0	0	0	0	1	0	0
T		1	0	0	1	0	0	1	0
G			1	0	0	0	0	0	1
C				1	0	1	0	0	0
T					1	0	0	1	0
C						1	0	0	0
A							1	0	0
T								1	0
G									1

ATGCTCATG
| | | | | | | |
ATGCTCATG

点阵图



用途:

1. 寻找两条序列间所有可能的比对;
2. 寻找蛋白质、**DNA**序列上正向或反向的重复序列;
3. 发现**RNA**上可能存在的互补区域。

优点:

1. 可以找到两个序列间所有可能的残基匹配;
2. 简单、易懂
3. 直观、整体性强

工具:

<https://www.ebi.ac.uk/Tools/psa/>


<https://blast.ncbi.nlm.nih.gov/Blast.cgi>

两条序列完全相同，主对角线形成连线


	A	T	G	C	T	C	A	T	G
A	1	0	0	0	0	0	1	0	0
T		1	0	0	1	0	0	1	0
G			1	0	0	0	0	0	1
C				1	0	1	0	0	0
T					1	0	0	1	0
C						1	0	0	0
A							1	0	0
T								1	0
G									1

ATGCTCATG
| | | | | | | |
ATGCTCATG

两条序列完全相同，主对角线形成连线



两条序列互为相反，反对角线形成连线



发现重复序列

	A	K	G	F	D	K	G	F	E
A	1	0	0	0	0	0	0	0	0
K		1	0	0	0	1	0	0	0
G			1	0	0	0	1	0	0
F				1	0	0	0	1	0
D					1	0	0	0	0
K		1				1	0	0	0
G			1				1	0	0
F				1				1	0
E									1

发现反向重复/回文

	A	U	G	C	A	C	G	U	C
A	1	0	0	0	1	0	0	0	0
U		1	0	0	0	0	0	1	0
G			1	0	0	0	1	0	0
C				1	0	1	0	0	0
A					1	0	0	0	0
C				1		1	0	0	1
G			1				1	0	0
U		1						1	0
C									1

发现RNA stem/loop

	A	U	G	U	A	G	C	A	U
A	1	0	0	0	1	0	0	1	0
U		1	0	1	0	0	0	0	1
G			1	0	0	1	0	0	0
C				0	0	0	0	0	1
U					0	0	0	0	1
A						0	0	1	0
C							1	0	0
A								1	0
U									1



不同序列之间的比对

FDSKTHRGHR

? ? ? ? ? ?

FESYWTHGHR

FDSK--THRGHR
FES-YWTH-GHR


FD-S-K-THRGHR
F-ESY-WTH-GHR




FDSK-T--HRGHR
FESYWTHGHR

FDSK-THRGHR
FESYWTH-GHR


配对，错配，插入和删除




两条序列存在相同的子串，
则对于每一个相同的子串对，
有一条与对角线平行的由标记点所组成的斜线



找两条序列的**最佳比对**（对应位置等同字符最多），实际上就是在矩阵标记图中找**非重叠平行斜线最长的组合**。




配对子串，插入和删除



对于**较长**的
序列，有很
多匹配的
字符，点阵图
变得非常**复
杂和模糊**。

↓ 序列2 ↓



点阵法的滑动窗口技术:

使用滑动窗口代替一次一个位点的比较, 是解决这个问题有效方法。


假设窗口大小为10, 相似度阈值为8, 则每次比较取10个连续的字符, 如相同的字符超过8个, 则标记,

基于滑动窗口的点矩阵方法可以明显地降低点阵图的噪声, 并且明确无误的指示出了两条序列间具有显著相似性的区域。


长度为4阈值为3的滑动窗口


	A	U	G	U	A	G	C	A	U
A	1				1			1	
U		1		1					1
G			1			1			
C									1
U									1
A								1	
C							1		
A								1	
U									1

长度为4阈值为3的滑动窗口




长度为4阈值为3的滑动窗口





(a)



(b)

(a) 对人类 (*Homo sapiens*) 与黑猩猩 (*Pongo pygmaeus*) 的 β 球蛋白基因序列进行比较的完整点阵图。(b) 利用滑动窗口对以上的两种球蛋白基因序列进行比较的点阵图, 其中窗口大小为10个核苷酸, 相似度阈值为8。

点阵序列比对的缺点

- 滑动窗口和阈值的选择过于经验化,
- 信噪比较低 ,
- 不适合进行高通量的数据分析,
- 对长序列, 计算时间长。

作为双序列比对的第一步, 点阵图提供了完整系统的轮廓信息

EMBOSS Water

Protein alignment

Nucleotide alignment

Web services

Help & Documentation

Bioinformatics Tools FAQ

 Feedback

 Share

Tools > Pairwise Sequence Alignment > EMBOSS Water

Pairwise Sequence Alignment (PROTEIN)

EMBOSS Water uses the Smith-Waterman algorithm (modified for speed enhancements) to calculate the local alignment of two sequences.

This is the form for protein sequences. Please go to the [nucleotide](#) form if you wish to align DNA or RNA sequences.

STEP 1 - Enter your protein sequences

Enter or paste your first **protein** sequence in any supported [format](#):

Or, [upload](#) a file: 未选择任何文件

Use a [example sequence](#) | [Clear sequence](#) | [See more example inputs](#)


AND

Enter or paste your second **protein** sequence in any supported [format](#):

Or, [upload](#) a file: 未选择任何文件

序列比对的打分体系

- ◆ 打分矩阵 (scoring matrix) 评价相似度
- ◆ 匹配、错配、插入、删除的得分
- ◆ 得分(+), 无分(0)或罚分(-)



简化的得分函数

匹配	$p(a, a)=1$
错配	$p(a, b)=0$
插入删除	$p(a, -)=p(-, b)=-1$

先寻找最佳比对


	P	K	D	F	C	K	A	L	V
P	1	0	0	0	0	0	0	0	0
K		1	0	0	0	1	0	0	0
F			0	1	0	0	0	0	0
T					0	0	0	0	0
K						1	0	0	0
A							1	0	0
I								0	0
V									1

PKDFCKALV
PK - FTKAIV

字符的关系：

1. 匹配
2. 删除或插入
3. 替换

简化打分机制：



由于序列长度不同，因此相对长度的得分更有意义：

$$\text{Sim}(s,t) = 2 \times \text{Score} / (m+n) = 2 \times 5 / (9+8) = 0.588$$

更复杂的实际情况：

不同类型的字符替换，其代价是不同的。

匹配 $p(a, a)=?$ 多种情况

错配 $p(a, b)=?$ 多种情况

插入删除 $p(a, -)=p(-, b)=-?$

打分机制

- 基本准则：处罚在进化过程中变异概率低的字符对，奖励高变异概率的字符对
- 理化性质相近的字符之间替换的代价更小得分高，进化更保守的字符之间替换得分高
- 遗传密码替换频率，自然选择对变换的容忍


打分矩阵的理化依据

➤ 几何属性

➤ 物理属性
(带电性与疏水性)

➤ 化学属性

➤ 氨基酸频率



核酸矩阵

1. 等价矩阵
2. BLAST矩阵
3. 转换—颠换矩阵（转移矩阵）

核酸 字母表 {A,C,G,T} 。

(1) 等价矩阵

最简单的得分矩阵，

相同核苷酸匹配得分 “1”

不同核苷酸替换得分 “0”

$$R_{ij} = \begin{cases} 1, & \text{匹配} \\ 0, & \text{替换} \end{cases}$$

R_{ij} : i行j列的元素

	A	T	C	G
A	1	0	0	0
T	0	1	0	0
C	0	0	1	0
G	0	0	0	1

(2) BLAST矩阵

BLAST是目前最流行的核酸序列比较程序，

匹配得分为“+5”
替换得分为“-4”

	A	T	C	G
A	5	-4	-4	-4
T	-4	5	-4	-4
C	-4	-4	5	-4
G	-4	-4	-4	5

(3) 转换—颠换矩阵（转移矩阵）

嘌呤（腺嘌呤A，鸟嘌呤G），两个环

嘧啶（胞嘧啶C，胸腺嘧啶T），一个环

转换(transition): 环数不变, $A \rightarrow G, C \rightarrow T$ 等

颠换(transversion): 环数变化, $A \rightarrow C, A \rightarrow T$ 等
进化过程中, 转换频率远比颠换高,

匹配得分“1”，转换得分“-1”，颠换得分“-5”。

	A	T	C	G
A	1	-5	-5	-1
T	-5	1	-1	-5
C	-5	-1	1	-5
G	-1	-5	-5	1

氨基酸矩阵

1. 遗传密码矩阵GCM
2. 疏水矩阵
3. PAM矩阵
4. BLOSUM矩阵

中文名称	英文名称	三字母缩写	单字母符号	密码子
甘氨酸	Glycine	Gly	G	GGU, GGC, GGA, GGG
丙氨酸	Alanine	Ala	A	GCU, GCC, GCA, GCG
缬氨酸	Valine	Val	V	GUU, GUC, GUA, GUG
亮氨酸	Leucine	Leu	L	CUU, CUC, CUA, CUG, UUA, UUG
异亮氨酸	Isoleucine	Ile	I	AUU, AUC, AUA
脯氨酸	Proline	Pro	P	CCU, CCA, CCG, CCC
苯丙氨酸	Phenylalanine	Phe	F	UUU, UUC
酪氨酸	Tyrosine	Tyr	Y	UAU, UAC
色氨酸	Tryptophan	Trp	W	UGG
丝氨酸	Serine	Ser	S	UCU, UCA, UCC, UCG, AGU, AGC
苏氨酸	Threonine	Thr	T	ACU, ACC, ACG, ACA
半胱氨酸	Cystine	Cys	C	UGU, UGC
蛋氨酸	Methionine	Met	M	AUG
天冬酰胺	Asparagine	Asn	N	AAU, AAC
谷氨酰胺	Glutarnine	Gln	Q	CAA, CAG
天冬氨酸	Asparticacid	Asp	D	GAU, GAC
谷氨酸	Glutamicacid	Glu	E	GAA, GAG
赖氨酸	Lysine	Lys	K	AAA, AAG
精氨酸	Arginine	Arg	R	CGU, CGC, CGG, CGA, AGA, AGG
组氨酸	Histidine	His	H	CAU, CAC

(1) 遗传密码矩阵GCM

□ 氨基酸替换时，密码子转变所需的碱基变化数

例如： 甲硫氨酸M=>色氨酸W
 (ATG) (TGG)
 替换值为： 2

GCM矩阵常用于进化距离的计算

- 优点是计算结果可以直接用于绘制进化树，
- 在蛋白质相似程度很低的序列比对中很少被使用。

	U	C	A	G	
U	UUU } 苯丙氨酸 UUC } UUA } 亮氨酸 UUG }	UCU } UCC } 丝氨酸 UCA } UCG }	UAU } 酪氨酸 UAC } UAA } 终止 UAG } 密码	UGU } 半胱氨酸 UGC } UGA } 终止 UGG } 色氨酸	U C A G
C	CUU } 亮氨酸 CUC } CUA } CUG }	CCU } CCC } 脯氨酸 CCA } CCG }	CAU } 组氨酸 CAC } CAA } 谷氨酰胺 CAG }	CGU } CGC } 精氨酸 CGA } CGG }	U C A G
A	AUU } 异亮氨酸 AUC } AUA } AUG } 甲硫氨酸 或 起始密码	ACU } ACC } 苏氨酸 ACA } ACG }	AAU } 天冬酰胺 AAC } AAA } 赖氨酸 AAG }	AGU } 丝氨酸 AGC } AGA } 精氨酸 AGG }	U C A G
G	GUU } 缬氨酸 GUC } GUA } GUG }	GCU } GCC } 丙氨酸 GCA } GCG }	GAU } 天冬氨酸 GAC } GAA } 谷氨酸 GAG }	GGU } GGC } 甘氨酸 GGA } GGG }	U C A G

遗传密码矩阵GCM

	A	S	G	L	K	V	T	P	E	D	N	I	Q	R	F	Y	C	H	M	W	Z	B	X
Ala=A	0	1	1	2	2	1	1	1	1	1	2	2	2	2	2	2	2	2	2	2	2	2	2
Ser=S	1	0	1	1	2	2	1	1	2	2	1	1	2	1	1	1	1	2	2	1	2	2	2
Gly=G	1	1	0	2	2	1	2	2	1	1	2	2	2	1	2	2	1	2	2	1	2	2	2
Leu=L	2	1	2	0	2	1	2	1	2	2	2	1	1	1	1	2	2	1	1	1	2	2	2
Lys=K	2	2	2	2	0	2	1	2	1	2	1	1	1	1	2	2	2	2	1	2	1	2	2
Val=V	1	2	1	1	2	0	2	2	1	1	2	1	2	2	1	2	2	2	1	2	2	2	2
Thr=T	1	1	2	2	1	2	0	1	2	2	1	1	2	1	2	2	2	2	1	2	2	2	2
Pro=P	1	1	2	1	2	2	1	0	2	2	2	2	1	1	2	2	2	1	2	2	2	2	2
Glu=E	1	2	1	2	1	1	2	2	0	1	2	2	1	2	2	2	2	2	2	2	1	2	2
Asp=D	1	2	1	2	2	1	2	2	1	0	1	2	2	2	2	1	2	1	2	2	2	1	2
Asn=N	2	1	2	2	1	2	1	2	2	1	0	1	2	2	2	1	2	1	2	2	2	1	2
Ile=I	2	1	2	1	1	1	1	2	2	2	1	0	2	1	1	2	2	2	1	2	2	2	2
Gln=Q	2	2	2	1	1	2	2	1	1	2	2	2	0	1	2	2	2	1	2	2	1	2	2
Arg=R	2	1	1	1	1	2	1	1	2	2	2	1	1	0	2	2	1	1	1	1	2	2	2
Phe=F	2	1	2	1	2	1	2	2	2	2	2	1	2	2	0	1	1	2	2	2	2	2	2
Tyr=Y	2	1	2	2	2	2	2	2	2	1	1	2	2	2	1	0	1	1	3	2	2	1	2
Cys=C	2	1	1	2	2	2	2	2	2	2	2	2	2	1	1	1	0	2	2	1	2	2	2
His=H	2	2	2	1	2	2	2	1	2	1	1	2	1	1	2	1	2	0	2	2	2	1	2
Met=M	2	2	2	1	1	1	1	2	2	2	2	1	2	1	2	3	2	2	0	2	2	2	2
Trp=W	2	1	1	1	2	2	2	2	2	2	2	2	2	1	2	2	1	2	2	0	2	2	2
Glx=Z	2	2	2	2	1	2	2	2	1	2	2	2	1	2	2	2	2	2	2	2	1	2	2
Asx=B	2	2	2	2	2	2	2	2	2	1	1	2	2	2	2	2	2	2	2	2	2	1	2
X	2	2	2	2	2	2	2	2	2	2	2	2	2	2	2	2	2	2	2	2	2	2	2

Met到Tyr的转变是仅有的三个位置都发生变化的转换


(2) 疏水矩阵

表征氨基酸残基替换前后疏水性变化。

- ✓ 疏水特性变化小，替换得分高
- ✓ 疏水特性变化大，替换得分低

甘氨酸	Glycine	Gly
丙氨酸	Alanine	Ala
缬氨酸	Valine	Val
亮氨酸	Leucine	Leu
异亮氨酸	Isoleucine	Ile
脯氨酸	Proline	Pro
苯丙氨酸	Phenylalanine	Phe
酪氨酸	Tyrosine	Tyr
色氨酸	Tryptophan	Trp
丝氨酸	Serine	Ser
苏氨酸	Threonine	Thr
半胱氨酸	Cystine	Cys
蛋氨酸	Methionine	Met
天冬酰胺	Asparagine	Asn
谷氨酰胺	Glutamine	Gln
天冬氨酸	Aspartic acid	Asp
谷氨酸	Glutamic acid	Glu
赖氨酸	Lysine	Lys
精氨酸	Arginine	Arg
组氨酸	Histidine	His


非极性R基



Gly

Ala

Val




Leu

Met

Ile


极性不带电荷R基



Ser

Thr

Cys




Pro

Asn

Gln

芳香R基




Phe

Tyr

Trp

带正电荷R基




Lys

Arg

His

带负电荷R基



Asp

Glu

蛋白质疏水矩阵

	R	K	D	E	B	Z	S	N	Q	G	X	T	H	A	C	M	P	V	L	I	Y	F	W
Arg=R	10	10	9	9	8	8	6	6	6	5	5	5	5	5	4	3	3	3	3	3	2	1	0
Lys=K	10	10	9	9	8	8	6	6	6	5	5	5	5	5	4	3	3	3	3	3	2	1	0
Asp=D	9	9	10	10	8	8	7	6	6	6	5	5	5	5	5	4	4	4	3	3	3	2	1
Glu=E	9	9	10	10	8	8	7	6	6	6	5	5	5	5	5	4	4	4	3	3	3	2	1
Asx=B	8	8	8	8	10	10	8	8	8	8	7	7	7	7	6	6	6	5	5	5	4	4	3
Glx=Z	8	8	8	8	10	10	8	8	8	8	7	7	7	7	6	6	6	5	5	5	4	4	3
Ser=S	6	6	7	7	8	8	10	10	10	10	9	9	9	9	8	8	7	7	7	7	6	6	4
Asn=N	6	6	6	6	8	8	10	10	10	10	9	9	9	9	8	8	8	7	7	7	6	6	4
Gln=Q	6	6	6	6	8	8	10	10	10	10	9	9	9	9	8	8	8	7	7	7	6	6	4
Gly=G	5	5	6	6	8	8	10	10	10	10	9	9	9	9	8	8	8	8	7	7	6	6	5
???=X	5	5	5	5	7	7	9	9	9	9	10	10	10	10	9	9	8	8	8	8	7	7	5
Thr=T	5	5	5	5	7	7	9	9	9	9	10	10	10	10	9	9	8	8	8	8	7	7	5
His=H	5	5	5	5	7	7	9	9	9	9	10	10	10	10	9	9	9	8	8	8	7	7	5
Ala=A	5	5	5	5	7	7	9	9	9	9	10	10	10	10	9	9	9	8	8	8	7	7	5
Cys=C	4	4	5	5	6	6	8	8	8	8	9	9	9	9	10	10	9	9	9	9	8	8	5
Met=M	3	3	4	4	6	6	8	8	8	8	9	9	9	9	10	10	10	10	9	9	8	8	7
Pro=P	3	3	4	4	6	6	7	8	8	8	8	8	9	9	9	10	10	10	9	9	9	8	7
Val=V	3	3	4	4	5	5	7	7	7	8	8	8	8	8	9	10	10	10	10	10	9	8	7
Leu=L	3	3	3	3	5	5	7	7	7	7	8	8	8	8	9	9	9	10	10	10	9	9	8
Ile=I	3	3	3	3	5	5	7	7	7	7	8	8	8	8	9	9	9	10	10	10	9	9	8
Tyr=Y	2	2	3	3	4	4	6	6	6	6	7	7	7	7	8	8	9	9	9	9	10	10	8
Phe=F	1	1	2	2	4	4	6	6	6	6	7	7	7	7	8	8	8	8	9	9	10	10	9
Trp=W	0	0	1	1	3	3	4	4	4	5	5	5	5	5	6	7	7	7	8	8	8	9	10

(3, 4) PAM矩阵 和 BLOSUM矩阵

统计进化相关蛋白质序列中氨基酸的相互替换率。

- PAM 统计于高度相似序列。
- BLOSUM统计于各种相似程度的序列。

(3) PAM矩阵(Point Accepted Mutation)

□ PAM是第一个广泛使用的氨基酸打分矩阵。

□ 1978年Dayhoff和她的同事们研究了71个相关蛋白质家族的1572个突变，发现蛋白质家族中氨基酸的替换**并不是随机的**。由此断言一些氨基酸的替换比其他替换更容易发生，其主要原因是这些替换不会对蛋白质的结构和功能产生太大的影响。

□ 如果两种特定的氨基酸之间替换发生得比较频繁，那么这一对氨基酸在得分矩阵中的**互换得分就比较高**。

	A	R	N	D	C
A	9867	2	9	10	3
R	1	9913	1	0	1
N	4	1	9822	36	0
D	6	0	42	9859	0
C	1	1	0	0	9973



PAM矩阵的构建

1. 构建相似度高（大于85%）的序列比对
2. 计算每个氨基酸j的**相对突变率** m_j ，相对突变率就是某种氨基酸被其他任意氨基酸替换的次数。比如，丙氨酸的相对突变率是通过计算丙氨酸与非丙氨酸残基比对的次数来得到
3. 针对每个氨基酸对i和j，计算氨基酸j被**特定氨基酸i**替换的次数。
4. 将以上**替换次数除以对应的相对替换率**
5. 利用每个氨基酸出现频度对其进行**标准化**，并将以上计算结果取常用对数,于是得到了PAM-1矩阵中的元素**PAM-1(i, j)**

这种矩阵被称作**对数几率矩阵（log odds matrix）**，因为其中的元素是根据每个氨基酸替换率的对数值来得到的

Dayhoff PAM 矩阵

C	S	T	P	A	G	N	D	E	Q	H	R	K	M	I	L	V	F	Y	W	
11.5	0.1	-0.5	-3.1	0.5	-2.0	-1.8	-3.2	-3.0	-2.4	-1.3	-2.2	-2.8	-0.9	-1.1	-1.5	0.0	-0.8	-0.5	-1.0	C
	2.2	1.5	0.4	1.1	0.4	0.9	0.5	0.2	0.2	-0.2	-0.2	0.1	-1.4	-1.8	-2.1	-1.0	-2.8	-1.9	-3.3	S
		2.5	0.1	0.6	-1.1	0.5	0.0	-0.1	0.0	-0.3	-0.2	0.1	-0.6	-0.6	-1.3	0.0	-2.2	-1.9	-3.5	T
			7.6	0.3	-1.6	-0.9	-0.7	-0.5	-0.2	-1.1	-0.9	-0.6	-2.4	-2.6	-2.3	-1.8	-3.8	-3.1	-5.0	P
				2.4	0.5	-0.3	-0.3	0.0	-0.2	-0.8	-0.6	-0.4	-0.7	-0.8	-1.2	0.1	-2.3	-2.2	-3.6	A
					6.6	0.4	0.1	-0.8	-1.0	-1.4	-1.0	-1.1	-3.5	-4.5	-4.4	-3.3	-5.2	-4.0	-4.0	G
						3.8	2.2	0.9	0.7	1.2	0.3	0.8	-2.2	-2.8	-3.0	-2.2	-3.1	-1.4	-3.6	N
							4.7	2.7	0.9	0.4	-0.3	0.5	-3.0	-3.8	-4.0	-2.9	-4.5	-2.8	-5.2	D
								3.6	1.7	0.4	0.4	1.2	-2.0	-2.7	-2.8	-1.9	-3.9	-2.7	-4.3	E
									2.7	1.2	1.5	1.5	-1.0	-1.9	-1.6	-1.5	-2.6	-1.7	-2.7	Q
										6.0	0.6	0.6	-1.3	-2.2	-1.9	-2.0	-0.1	2.2	-0.8	H
											4.7	2.7	-1.7	-2.4	-2.2	-2.0	-3.2	-1.8	-1.6	R
												3.2	-1.4	-2.1	-2.1	-1.7	-3.3	-2.1	-3.5	K
													4.3	2.5	2.8	1.6	1.6	-0.2	-1.0	M
														4.0	2.8	3.1	1.0	-0.7	-1.8	I
															4.0	1.8	2.0	0.0	-0.7	L
																3.4	0.1	-1.1	-2.6	V
																	7.0	5.1	3.6	F
																		7.8	4.1	Y
																			14.2	W

蛋白质疏水矩阵

	R	K	D	E	B	Z	S	N	Q	G	X	T	H	A	C	M	P	V	L	I	Y	F	W
Arg=R	10	10	9	9	8	8	6	6	6	5	5	5	5	5	4	3	3	3	3	3	2	1	0
Lys=K	10	10	9	9	8	8	6	6	6	5	5	5	5	5	4	3	3	3	3	3	2	1	0
Asp=D	9	9	10	10	8	8	7	6	6	6	5	5	5	5	5	4	4	4	3	3	3	2	1
Glu=E	9	9	10	10	8	8	7	6	6	6	5	5	5	5	5	4	4	4	3	3	3	2	1
Asx=B	8	8	8	8	10	10	8	8	8	8	7	7	7	7	6	6	6	5	5	5	4	4	3
Glx=Z	8	8	8	8	10	10	8	8	8	8	7	7	7	7	6	6	6	5	5	5	4	4	3
Ser=S	6	6	7	7	8	8	10	10	10	10	9	9	9	9	8	8	7	7	7	7	6	6	4
Asn=N	6	6	6	6	8	8	10	10	10	10	9	9	9	9	8	8	8	7	7	7	6	6	4
Gln=Q	6	6	6	6	8	8	10	10	10	10	9	9	9	9	8	8	8	7	7	7	6	6	4
Gly=G	5	5	6	6	8	8	10	10	10	10	9	9	9	9	8	8	8	8	7	7	6	6	5
???=X	5	5	5	5	7	7	9	9	9	9	10	10	10	10	9	9	8	8	8	8	7	7	5
Thr=T	5	5	5	5	7	7	9	9	9	9	10	10	10	10	9	9	8	8	8	8	7	7	5
His=H	5	5	5	5	7	7	9	9	9	9	10	10	10	10	9	9	9	8	8	8	7	7	5
Ala=A	5	5	5	5	7	7	9	9	9	9	10	10	10	10	9	9	9	8	8	8	7	7	5
Cys=C	4	4	5	5	6	6	8	8	8	8	9	9	9	9	10	10	9	9	9	9	8	8	5
Met=M	3	3	4	4	6	6	8	8	8	8	9	9	9	9	10	10	10	10	9	9	8	8	7
Pro=P	3	3	4	4	6	6	7	8	8	8	8	8	9	9	9	10	10	10	9	9	9	8	7
Val=V	3	3	4	4	5	5	7	7	7	8	8	8	8	8	9	10	10	10	10	10	9	8	7
Leu=L	3	3	3	3	5	5	7	7	7	7	8	8	8	8	9	9	9	10	10	10	9	9	8
Ile=I	3	3	3	3	5	5	7	7	7	7	8	8	8	8	9	9	9	10	10	10	9	9	8
Tyr=Y	2	2	3	3	4	4	6	6	6	6	7	7	7	7	8	8	9	9	9	9	10	10	8
Phe=F	1	1	2	2	4	4	6	6	6	6	7	7	7	7	8	8	8	8	9	9	10	10	9
Trp=W	0	0	1	1	3	3	4	4	4	5	5	5	5	5	6	7	7	7	8	8	8	9	10

◆ 问题：无法表征低相似性的序列之间的氨基酸替换关系。

● 解决方法：

将PAM-1自乘N次，可以得到矩阵PAM-N。

PAM矩阵（Point Accepted Mutation）

序列相似度 =	14% - 27%	40%	50%	60%
打分矩阵 =	PAM250	PAM120	PAM80	PAM60

(4) BLOSUM矩阵 (Block Substitution Matrices)

□ 不少情况下Dayhoff的PAM记分矩阵可能失效，因为其置换速率是通过至少具有85%一致性的序列对位排列所获得的。那些进化距离较远的矩阵是**推算出来**而不是直接统计得到的，其准确率受到限制，这就需要使用新的记分矩阵。

□ Henikoff (1992)提出了模块置换矩阵的概念

□ 模块(Blocks): 是指在蛋白质序列比对中(局部多序列比对)的高度保守区域




- ◆ PAM矩阵是从蛋白质序列的**全局比对**结果推导出来的，而BLOSUM矩阵则是从蛋白质序列块（短序列）**局部比对**而推导出来的。
- ◆ 基本数据来源于BLOCKS数据库，其中包括了局部多重比对（包含较远的相关序列，与在PAM中使用较近的相关序列相反）。优点在于可以通过**直接观察**而**不是通过外推**获得远同源序列中氨基酸的关系。
- ◆ 不同相似程度来源的数据，可生产适用于不同同源比对的工作：
 - BLOSUM62：适用于相似度约为 62% 的序列比对
 - BLOSUM80：适用于相似度约为 80% 的序列比对

BLOSUM-62矩阵

C	4																			
S	-1	5																		
T	-2	0	6																	
P	-2	-2	1	6																
A	0	-3	-3	-3	9															
G	-1	1	0	0	-3	5														
N	-1	0	0	2	-4	2	5													
D	0	-2	0	-1	-3	-2	-2	6												
E	-2	0	1	-1	-3	0	0	-2	8											
Q	-1	-3	-3	-3	-1	-3	-3	-4	-3	4										
H	-1	-2	-3	-4	-1	-2	-3	-4	-3	2	4									
R	-1	2	0	-1	-3	1	1	-2	-1	-3	-2	4								
K	-1	-1	-2	-3	-1	0	-2	-3	-2	1	2	-1	5							
M	-2	-3	-3	-3	-2	-3	-3	-3	-1	0	0	-3	0	6						
I	-1	-2	-2	-1	-3	-1	-1	-2	-2	-3	-3	-1	-2	-4	7					
L	1	-1	1	0	-1	0	0	0	-1	-2	-2	0	-1	-2	-1	4				
V	0	-1	0	-1	-1	-1	-1	-2	-2	-1	-1	-1	-1	-2	-1	1	5			
F	-3	-3	-4	-4	-2	-2	-3	-2	-2	-3	-2	-3	-1	1	-4	-3	-2	11		
Y	-2	-2	-2	-3	-2	-1	-2	-3	-2	-1	-1	-2	-1	3	-3	-2	-2	2	7	
W	0	-3	-3	-3	-1	-2	-2	-3	-3	3	1	-2	1	-1	-2	-2	0	-3	-1	4
	C	S	T	P	A	G	N	D	E	Q	H	R	K	M	I	L	V	F	Y	W

如何选择合适的矩阵？



对于相似度越低的序列比对工作
适用的**PAM**矩阵，后面的数字越大，
适用的**BLOSUM**矩阵，后面的数字越小。

不同的记分方法(模型)的特点

(1) 基于“一致性”的记分

在这种记分方法中，仅统计序列位点间的一致性。匹配的位点记正分(通常为1)，非匹配的位点记0分。

优点：简单明了，适用于高度相似性序列。

缺点：没有考虑非匹配位点间的不等价问题；在对相似性较低的序列进行对位排列时，效果尤差。

(2) 基于“遗传密码”的记分

该方法考虑到当一个氨基酸转换成另一个氨基酸时，在基因组水平上碱基变化的最小数目。

优点：具有分子生物学基础。

缺点：考虑随机因素较少。例如，碱基变化数目并非总是与氨基酸序列间的相似性相对应。

(3) 基于“化学相似性”的记分方式

该方法是对一致性记分方法的局部改进。

例如，Mclachlan和Feng 等结合氨基酸的性质(如极性、电荷、大小和结构特征)，对不同氨基酸进行了加权。

优点：考虑了氨基酸和蛋白质的结构与性质。例如，一个氨基酸从极性到非极性的改变对蛋白质的结构与功能的影响，可能比具有相似性质的氨基酸间的突变要显著一些。

缺点：并非所有蛋白质的结构与功能的改变都可以用简单的记分描述。

(4) 基于“观察突变”的记分


该方法考虑了对位排列序列中所实际观察到的突变频率。PAM矩阵和BLOSUM矩阵就属于这类方法。

优点：以自然界中**真实事件为基础**。与其他记分方法相比，真实的突变频率更有助于解释序列间的**进化关系**。


缺点：突变频率是从已对位排列的序列中获得的，而初始的对位排列必须人工进行，较为**复杂且容易发生错误**。

简化模型：点阵图

复杂问题：序列对打分矩阵



寻找最优路径



序列比对:

VDSCY

和

VESLCY

空位罚分d=-11

序列对打分矩阵，最优路径怎么找？

	V	D	S	C	Y
V	4	-3	-2	-1	-1
E	-2	2	0	-4	-2
S	-2	0	4	-1	-2
L	1	-4	-2	-1	-1
C	-1	-3	-1	9	-2
Y	-1	-3	-2	-2	7



需要高效算法


➤ 计算所有比对可能系，求得所有路径。

➤ 但所有比对数是序列长度的指数函数，计算量大，需高效的算法。

➤ 3^{n*n}

➤ $N=10$, 需要 $5*10^{47}$

	V	D	S	C	Y
V	4	3	-2	-1	-1
E	-2	2	0	-4	-2
S	-2	0	4	-1	-2
L	1	-4	-2	-1	-1
C	-1	-3	-1	9	-2
Y	-1	-3	-2	-2	7



约等于 10^{30} 年


动态规划

GPS中的最优路径


全球定位系统GPS(Global Positioning System)可以为我们计算出满足各种不同要求的、从出发地到目的地最优路径，可能是花费时间最短，也可能是过路费最少。GPS寻找最优路径的算法就是动态规划算法。



计算顶点0到顶点6的最短路径



计算顶点0到顶点6的最短路径



序列比对:

VDSCY

和

VESLCY

空位罚分 $d = -11$

构建配对得分矩阵

	V	D	S	C	Y
V	4	-3	-2	-1	-1
E	-2	2	0	-4	-2
S	-2	0	4	-1	-2
L	1	-4	-2	-1	-1
C	-1	-3	-1	9	-2
Y	-1	-3	-2	-2	7

构建最佳上游节点矩阵

	V	D	S	C	Y
V	$S_{i-1, j-1}$	$S_{i-1, j}$			
E	$S_{i, j-1}$	$S_{i, j}$			
S					
L					
C					
Y					

VD-
VE

VD
VE

VD
VE-

要求解 S_{ij} 的分数，我们必须先知道

$S_{i-1, j-1}$, $S_{i-1, j}$, $S_{i, j-1}$ 的分数，这种方法叫做
递归算法；

采用这种方法，可以把大的问题分割成小的问题逐一解决，即**动态规划算法**；需要存储如何得到 S_{ij} 分数的过程。

构建最佳上游节点矩阵

	V	D	S	C	Y
V	$S_{i-1, j-1}$	$S_{i-1, j}$			
E	$S_{i, j-1}$	$S_{i, j}$			
S					
L					
C					
Y					

Needleman-Wunsch算法;

$$S_{ij} = \max \begin{cases} S_{i-1, j-1} + \sigma(x_i, y_j) \\ S_{i-1, j} + d \text{ (从上到下)} \\ S_{i, j-1} + d \text{ (从左到右)} \end{cases}$$

构建最佳上游节点矩阵

	Gap	V	D	S	C	Y
Gap	0	-11				
V	-11	4				
E						
S						
L						
C						
Y						

Needleman-Wunsch算法;

$$S_{ij} = \max \begin{cases} S_{i-1,j-1} + \sigma(x_i, y_j) \\ S_{i-1,j} + d \text{ (从上到下)} \\ S_{i,j-1} + d \text{ (从左到右)} \end{cases}$$

配对得分矩阵

	V	D	S	C	Y
V	4	-3	-2	-1	-1
E	-2	2	0	-4	-2
S	-2	0	4	-1	-2
L	1	-4	-2	-1	-1
C	-1	-3	-1	9	-2
Y	-1	-3	-2	-2	7

构建最佳上游节点矩阵

	Gap	V	D	S	C	Y
Gap	0	-11	-22			
V	-11	4	-7			
E						
S						
L						
C						
Y						

$V \leftrightarrow D: -3$

最佳上游节点矩阵

	Gap	V	D	S	C	Y
Gap	0	-11	-22	-33	-44	-55
V	-11	4	-7	-18	-29	-40
E	-22	-7	6	-5	-16	-27
S	-33	-18	-5	10	-1	-12
L	-44	-29	-16	-1	9	-2
C	-55	-40	-27	-12	8	7
Y	-66	-51	-38	-23	-3	15

回溯

	Gap	V	D	S	C	Y
Gap	0	-11	-22	-33	-44	-55
V	-11	4	-7	-18	-29	-40
E	-22	-7	6	-5	-16	-27
S	-33	-18	-5	10	-1	-12
L	-44	-29	-16	-1	9	-2
C	-55	-40	-27	-12	8	7
Y	-66	-51	-38	-23	-3	15

回溯

	Gap	V	D	S	C	Y
Gap	0	-11	-22	-33	-44	-55
V	-11	4	-7	-18	-29	-40
E	-22	-7	6	-5	-16	-27
S	-33	-18	-5	10	-1	-12
L	-44	-29	-16	-1	9	-2
C	-55	-40	-27	-12	8	7
Y	-66	-51	-38	-23	-3	15

回溯

	Gap	V	D	S	C	Y
Gap	0	-11	-22	-33	-44	-55
V	-11	4	-7	-18	-29	-40
E	-22	-7	6	-5	-16	-27
S	-33	-18	-5	10	-1	-12
L	-44	-29	-16	-1	9	-2
C	-55	-40	-27	-12	8	7
Y	-66	-51	-38	-23	-3	15

回溯

	Gap	V	D	S	C	Y
Gap	0	-11	-22	-33	-44	-55
V	-11	4	-7	-18	-29	-40
E	-22	-7	6	-5	-16	-27
S	-33	-18	-5	10	-1	-12
L	-44	-29	-16	-1	9	-2
C	-55	-40	-27	-12	8	7
Y	-66	-51	-38	-23	-3	15

比对结果:

V D S - C Y

V E S L C Y

	Gap	V	D	S	C	Y
Gap	0	-11	-22	-33	-44	-55
V	-11	4	-7	-18	-29	-40
E	-22	-7	6	-5	-16	-27
S	-33	-18	-5	10	-1	-12
L	-44	-29	-16	-1	9	-2
C	-55	-40	-27	-12	8	7
Y	-66	-51	-38	-23	-3	15

Bioinformatics

- LQ R H K R T H T G E K P Y E - C N Q C G K A F A Q -
LQ R H K R T H T G E K P Y M N V I N M V K P L H N S
- - - - - : - - - - -

-
- Diagram illustrating the alignment of a DNA sequence with an EST, cDNA, or protein sequence. The DNA sequence is shown as a black line with labels "DNA序列", "外显子" (exon), and "内含子" (intron). The EST, cDNA, or protein sequence is shown as a red line with labels "EST, cDNA或蛋白质序列". Red dashed lines indicate the alignment of exons and introns, with "GT" and "AG" labels indicating splice sites.

局部优化比对

- 下例：局部优化打分
- 两条序列如下：

L	D	S	C	H	
G	E	S	L	C	K

- 目标：使用局部优化算法寻找最佳比对的结果

- 对全局比对策略稍作修改可得到局部最优比对算法。
- 比对的路径不需要到达搜索图的尽头,如果某种比对的分值不会因为增加比对的数量而增加时,这种比对就是最佳的。
- 依赖于记分系统的性质: 因为某种路径的记分会在不匹配的序列段减少,当分值降为零时,路径的延展将会终止,一个新的路径就会产生。

局部比对

	Gap	L	D	S	C	H
Gap	0	0	0	0	0	0
G	0	S_{ij}				
E	0					
S	0					
L	0					
C	0					
K	0					

gap: -11, 线性罚分模型。

Smith-Waterman算法;


$$S_{ij} = \max \begin{cases} S_{i-1,j-1} + \sigma(x_i, y_j) \\ S_{i-1,j} + d \text{ (从上到下)} \\ S_{i,j-1} + d \text{ (从左到右)} \\ 0 \end{cases}$$

BLOSUM62替代矩阵

C	9																			
S	-1	4																		
T	-1	1	5																	
P	-3	-1	-1	7																
A	0	1	0	-1	4															
G	-3	0	-2	-2	0	6														
N	-3	1	0	-2	-2	0	6													
D	-3	0	-1	-1	-2	-1	1	6												
E	-4	0	-1	-1	-1	-2	0	2	5											
Q	-3	0	-1	-1	-1	-2	0	0	2	5										
H	-3	-1	-2	-2	-2	-2	1	-1	0	0	8									
R	-3	-1	-1	-2	-1	-2	0	-2	0	1	0	5								
K	-3	0	-1	-1	-1	-2	0	-1	1	1	-1	2	5							
M	-1	-1	-1	-2	-1	-3	-2	-3	-2	0	-2	-1	-1	5						
I	-1	-2	-1	-3	-1	-4	-3	-3	-3	-3	-3	-3	-3	1	4					
L	-1	-2	-1	-3	-1	-4	-3	-4	-3	-2	-3	-2	-2	2	2	4				
V	-1	-2	0	-2	0	-3	-3	-3	-2	-2	-3	-3	-2	1	3	1	4			
F	-2	-2	-2	-4	-2	-3	-3	-3	-3	-3	-1	-3	-3	0	0	0	-1	6		
Y	-2	-2	-2	-3	-2	-3	-2	-3	-2	-1	2	-2	-2	-1	-1	-1	-1	3	7	
W	-2	-3	-2	-4	-3	-2	-4	-4	-3	-2	-2	-3	-3	-1	-3	-2	-3	1	2	11
	C	S	T	P	A	G	N	D	E	Q	H	R	K	M	I	L	V	F	Y	W

局部优化比对 (2)

	Gap	L	D	S	C	H
Gap	0	0	0	0	0	0
G	0	0				
E	0					
S	0					
L	0					
C	0					
K	0					



局部优化比对 (3)

	Gap	L	D	S	C	H
Gap	0	0	0	0	0	0
G	0	0	0			
E	0					
S	0					
L	0					
C	0					
K	0					

The diagram illustrates a sequence alignment optimization step. Red arrows indicate the path of maximum score from the 'Gap' row to the 'G' row. The scores for the alignment are: -4 for the alignment of 'Gap' with 'L', and -11 for the alignment of 'G' with 'D'. The scores for the alignment of 'G' with 'D' are also shown as -11.

比对结果:

L D S - C H
G E S L C K

	Gap	L	D	S	C	H
Gap	0	0	0	0	0	0
G	0	0	0	0	0	0
E	0	0	2	2	1	0
S	0	0	2	6	1	0
L	0	4	0	0	5	2
C	0	0	1	0	9	2
K	0	0	0	0	0	8

序列比对的分值

L D S – C H

G E S L C K

- 1. Smith-waterman算法打分：9分
- 2. 直接打分： $2+4-11+9=4$

全局比对和局部比对算法的差异

全局比对

Needleman-Wunsch算法;

$$S_{ij} = \max \begin{cases} S_{i-1, j-1} + \sigma(x_i, y_j) \\ S_{i-1, j} + d \text{ (从上到下)} \\ S_{i, j-1} + d \text{ (从左到右)} \end{cases}$$

局部比对

Smith-Waterman算法;

$$S_{ij} = \max \begin{cases} S_{i-1, j-1} + \sigma(x_i, y_j) \\ S_{i-1, j} + d \text{ (从上到下)} \\ S_{i, j-1} + d \text{ (从左到右)} \\ 0 \end{cases}$$

本章小结

- ✓ 序列比对的概念
- ✓ 同源性和相似性
- ✓ 点阵图
- ✓ 打分矩阵
- ✓ 动态规划寻找最优路径
- ✓ 全局比对和局部比对