多序列比对的原理以及clustal在多序列比对中的应用

内容提要

- 多序列比对的意义
- 多序列比对的方法
- 自动多序列比对的算法
- **Clustalx的使用（clustal法）**
- 实例分析

探索多个生物分子间的关系

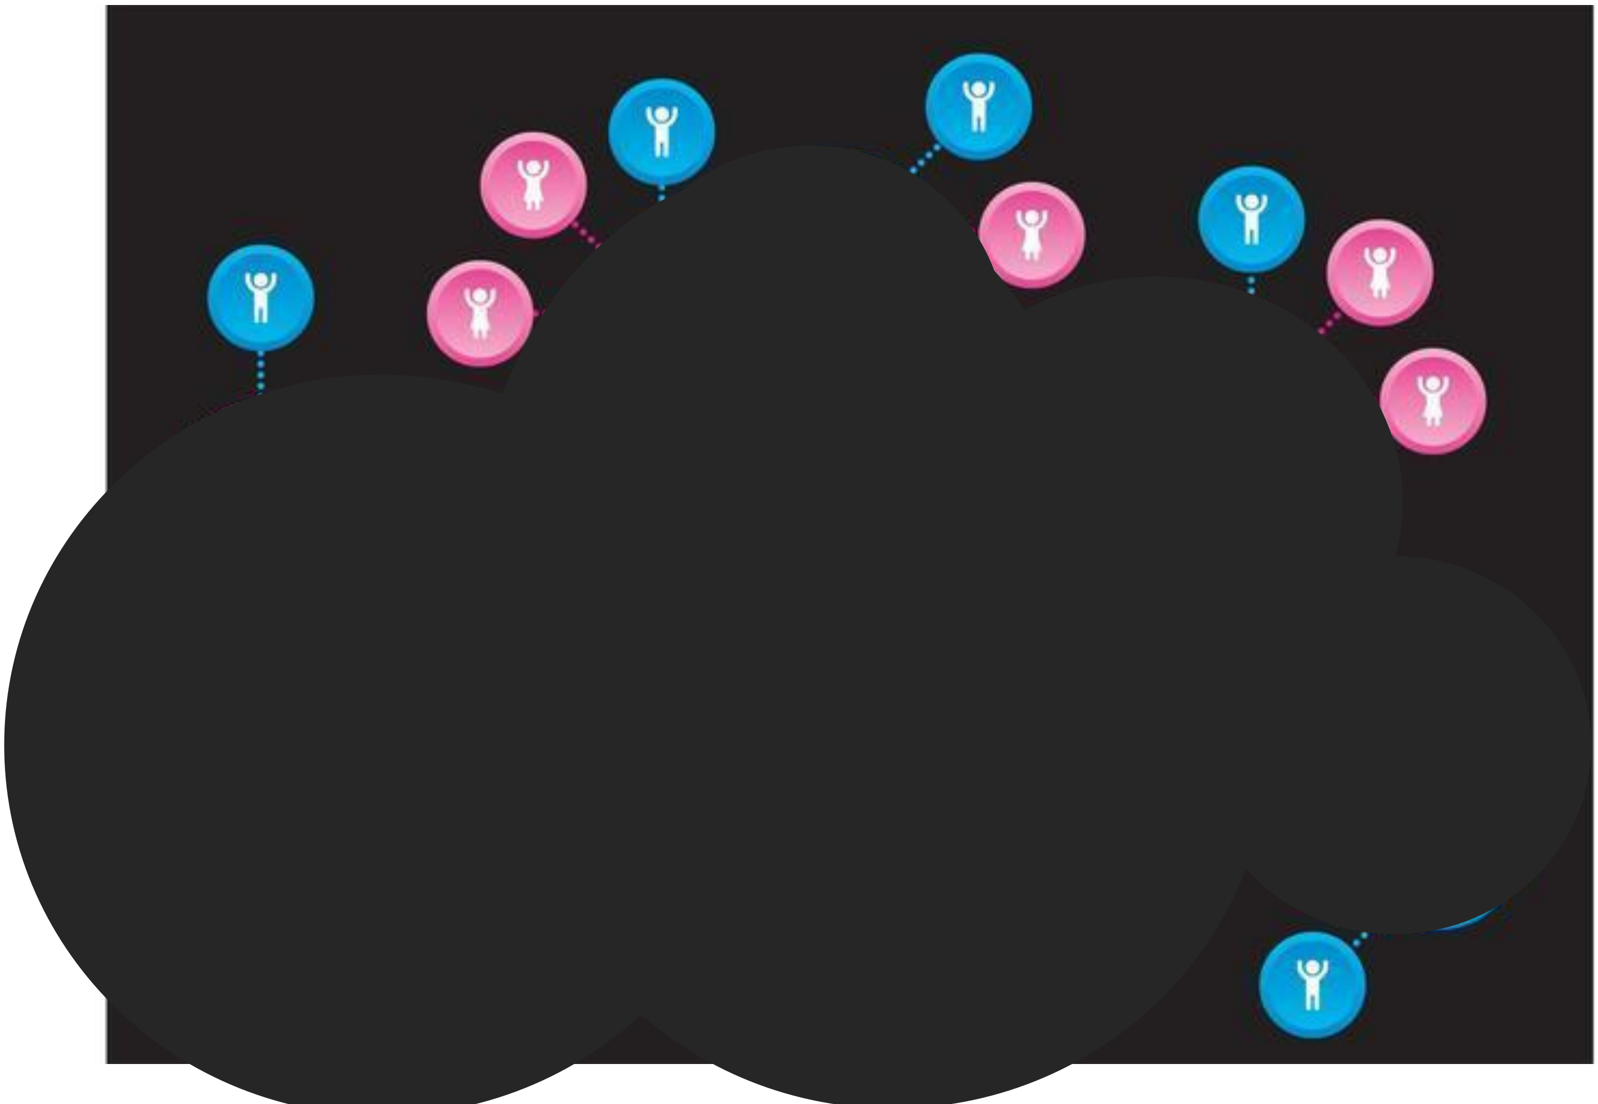

多序列比对的作用

- 用于描述一个同源基因之间的亲缘关系的远近，应用到分子进化分析中。
- 用于描述一组序列之间的相似性关系，以便了解一个基因家族的基本关系特征，寻找motif，保守区域等。构建profile，打分矩阵等。

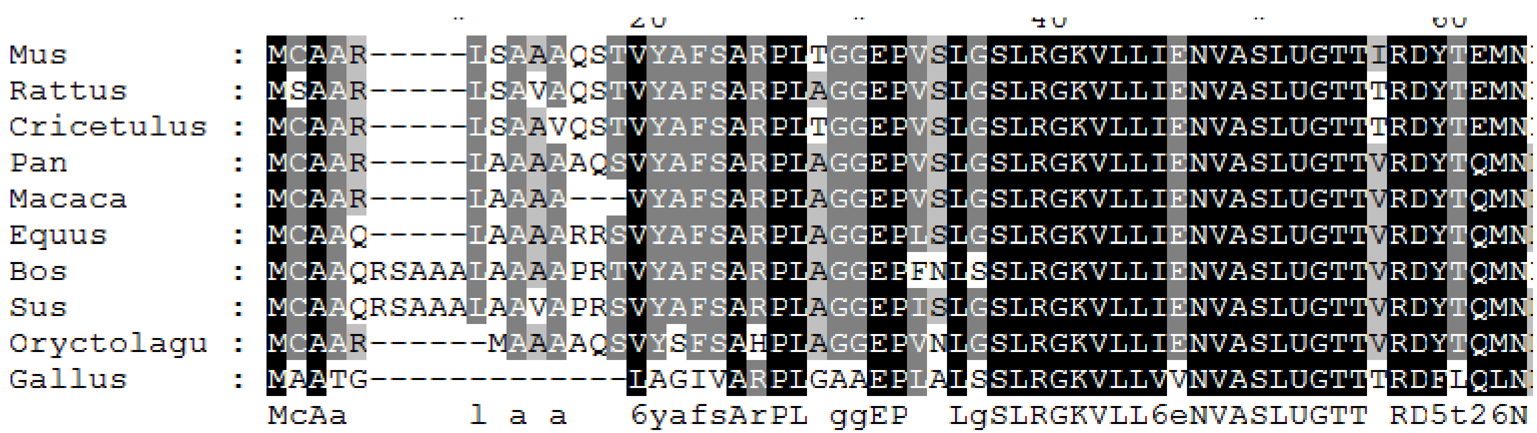

多序列比对的方法

```
ABCD       A B C   D
ABCCD      A B C C D
BCD          B C   D
```

基本上多序列比对可以分为

1.手工比对（辅助编辑软件如bioedit，seaview，Genedoc等）

通过辅助软件的不同颜色显示不同残基，靠分析者的观察来改变比对的状态。

2.计算机程序自动比对

通过特定的算法（如**同步法，渐进法**等），由计算机程序自动搜索最佳的多序列比对状态。

自动多序列比对的算法

1.同步法

- 将序列两两比对时的二维动态规划矩阵扩展到三维矩阵。
- 即用矩阵的维数来反映比对的序列数目。
- 这种方法的计算量很大，对于计算机系统的资源要求比较高。

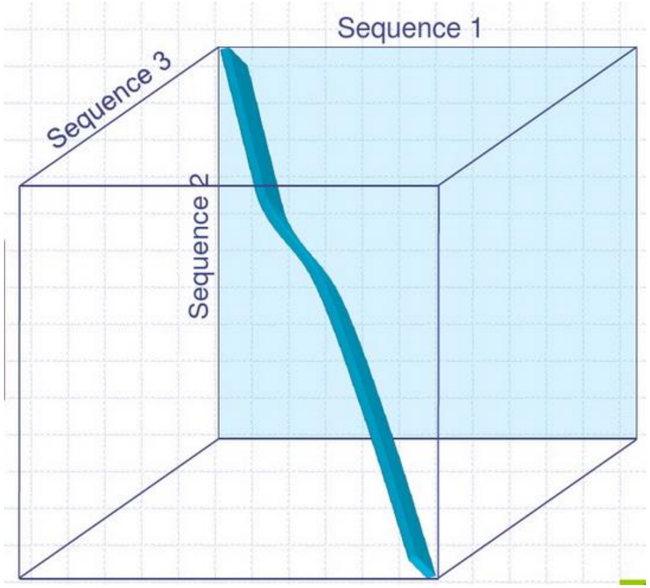

2-D vs 3-D 比对网格

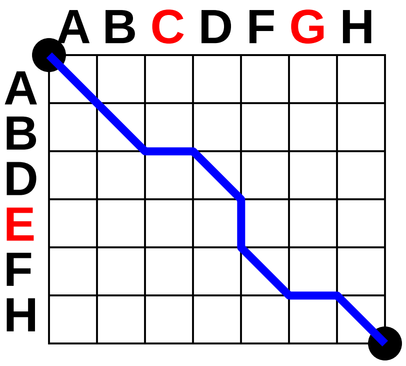

2-D 矩阵

ABCD–FGH
AB– DEF–H

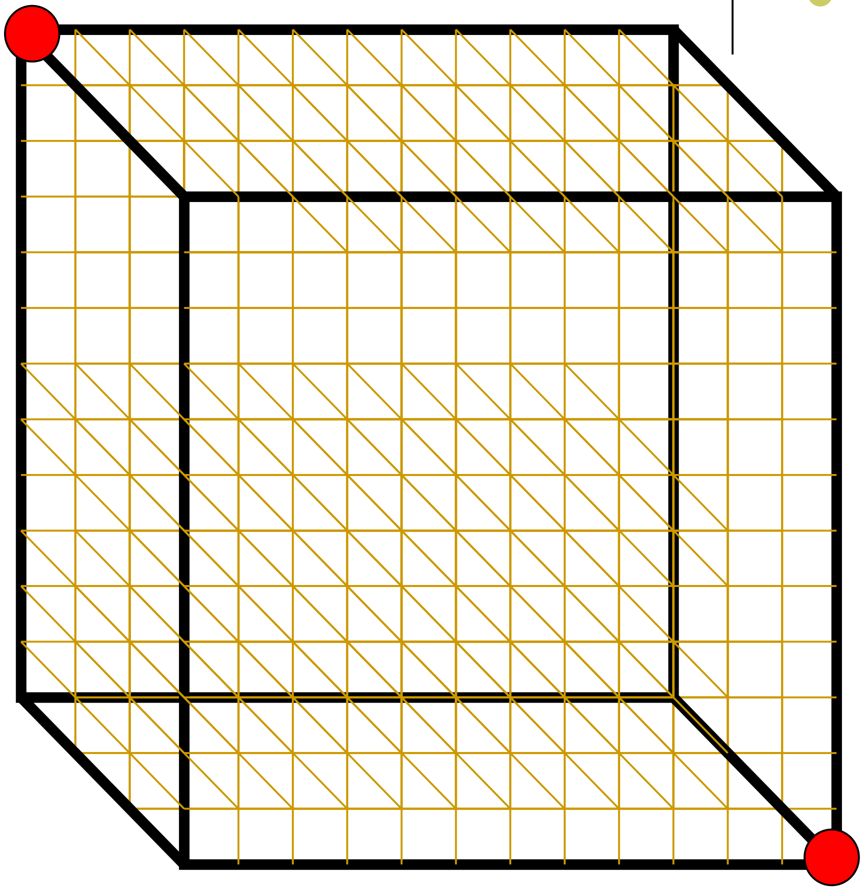

3-D 矩阵

回顾双序列比对算法

序列比对：

VDSCY

和

VESLCY

空位罚分d=-11

C	9																			
S	-1	4																		
T	-1	1	5																	
P	-3	-1	-1	7																
A	0	1	0	-1	4															
G	-3	0	-2	-2	0	6														
N	-3	1	0	-2	-2	0	6													
D	-3	0	-1	-1	-2	-1	1	6												
E	-4	0	-1	-1	-1	-2	0	2	5											
Q	-3	0	-1	-1	-1	-2	0	0	2	5										
H	-3	-1	-2	-2	-2	-2	1	-1	0	0	8									
R	-3	-1	-1	-2	-1	-2	0	-2	0	1	0	5								
K	-3	0	-1	-1	-1	-2	0	-1	1	1	-1	2	5							
M	-1	-1	-1	-2	-1	-3	-2	-3	-2	0	-2	-1	-1	5						
I	-1	-2	-1	-3	-1	-4	-3	-3	-3	-3	-3	-3	-3	1	4					
L	-1	-2	-1	-3	-1	-4	-3	-4	-3	-2	-3	-2	-2	2	2	4				
V	-1	-2	0	-2	0	-3	-3	-3	-2	-2	-3	-3	-2	1	3	1	4			
F	-2	-2	-2	-4	-2	-3	-3	-3	-3	-3	-1	-3	-3	0	0	0	-1	6		
Y	-2	-2	-2	-3	-2	-3	-2	-3	-2	-1	2	-2	-2	-1	-1	-1	-1	3	7	
W	-2	-3	-2	-4	-3	-2	-4	-4	-3	-2	-2	-3	-3	-1	-3	-2	-3	1	2	11
	C	S	T	P	A	G	N	D	E	Q	H	R	K	M	I	L	V	F	Y	W

BLOSUM62

构建配对得分矩阵

	V	D	S	C	Y
V	4	-3	-2	-1	-1
E	-2	2	0	-4	-2
S	-2	0	4	-1	-2
L	1	-4	-2	-1	-1
C	-1	-3	-1	9	-2
Y	-1	-3	-2	-2	7

构建最佳上游节点矩阵

	V	D	S	C	Y
V	$S_{i-1,\ j-1}$	$S_{i-1,\ j}$			
E	$S_{i,\ j-1}$	$\mathbf{S_{i,\ j}}$			
S					
L					
C					
Y					

D-
VE

VD
VE

VD
E-

要求解S_{ij}的分数，我们必须先知道

$S_{i-1,j-1}$，$S_{i-1,j}$，$S_{i,j-1}$的分数，这种方法叫做递归算法；

采用这种方法，可以把大的问题分割成小的问题逐一解决，即动态规划算法；需要存储如何得到S_{ij}分数的过程。

构建最佳上游节点矩阵

	V	D	S	C	Y
V	$S_{i-1,\ j-1}$	$S_{i-1,\ j}$			
E	$S_{i,\ j-1}$	$\mathbf{S_{i,\ j}}$			
S					
L					
C					
Y					

Needleman-Wunsch算法：

$$S_{ij} = \text{max of} \begin{cases} S_{i-1,\ j-1} + \sigma(x_i,\ y_j) \\ S_{i-1,\ j} + d \ (\text{从上到下}) \\ S_{i,\ j-1} + d \ (\text{从左到右}) \end{cases}$$

构建最佳上游节点矩阵

	Gap	V	D	S	C	Y
Gap	0	-11				
V	-11	4				
E						
S						
L						
C						
Y						

Needleman-Wunsch算法：

$$S_{ij} = \max \text{ of } \begin{cases} S_{i-1,\, j-1} + \sigma(x_i,\, y_j) \\ S_{i-1,\, j} + d \ (\text{从上到下}) \\ S_{i,\, j-1} + d \ (\text{从左到右}) \end{cases}$$

配对得分矩阵

	V	D	S	C	Y
V	4	-3	-2	-1	-1
E	-2	2	0	-4	-2
S	-2	0	4	-1	-2
L	1	-4	-2	-1	-1
C	-1	-3	-1	9	-2
Y	-1	-3	-2	-2	7

构建最佳上游节点矩阵

	Gap	V	D	S	C	Y
Gap	0	-11	-3 -22			
V	-11	4	-7			
E						
S						
L						
C						
Y						

-11

-11

V⇔D: -3

最佳上游节点矩阵

	Gap	V	D	S	C	Y
Gap	0	-11	-22	-33	-44	-55
V	-11	4	-7	-18	-29	-40
E	-22	-7	6	-5	-16	-27
S	-33	-18	-5	10	-1	-12
L	-44	-29	-16	-1	9	-2
C	-55	-40	-27	-12	8	7
Y	-66	-51	-38	-23	-3	15

回溯

	Gap	V	D	S	C	Y
Gap	0	-11	-22	-33	-44	-55
V	-11	4	-7	-18	-29	-40
E	-22	-7	6	-5	-16	-27
S	-33	-18	-5	10	-1	-12
L	-44	-29	-16	-1	9	-2
C	-55	-40	-27	-12	8	7
Y	-66	-51	-38	-23	-3	15

回溯

	Gap	V	D	S	C	Y
Gap	0	-11	-22	-33	-44	-55
V	-11	4	-7	-18	-29	-40
E	-22	-7	6	-5	-16	-27
S	-33	-18	-5	10	-1	-12
L	-44	-29	-16	-1	9	-2
C	-55	-40	-27	-12	8	7
Y	-66	-51	-38	-23	-3	15

回溯

	Gap	V	D	S	C	Y
Gap	0	-11	-22	-33	-44	-55
V	-11	4	-7	-18	-29	-40
E	-22	-7	6	-5	-16	-27
S	-33	-18	-5	10	-1	-12
L	-44	-29	-16	-1	9	-2
C	-55	-40	-27	-12	8	7
Y	-66	-51	-38	-23	-3	15

回溯

	Gap	V	D	S	C	Y
Gap	0	-11	-22	-33	-44	-55
V	-11	4	-7	-18	-29	-40
E	-22	-7	6	-5	-16	-27
S	-33	-18	-5	10	-1	-12
L	-44	-29	-16	-1	9	-2
C	-55	-40	-27	-12	8	7
Y	-66	-51	-38	-23	-3	15

比对结果：

V D S – C Y

V E S L C Y

	Gap	V	D	S	C	Y
Gap	0	-11	-22	-33	-44	-55
V	-11	4	-7	-18	-29	-40
E	-22	-7	6	-5	-16	-27
S	-33	-18	-5	10	-1	-12
L	-44	-29	-16	-1	9	-2
C	-55	-40	-27	-12	8	7
Y	-66	-51	-38	-23	-3	15

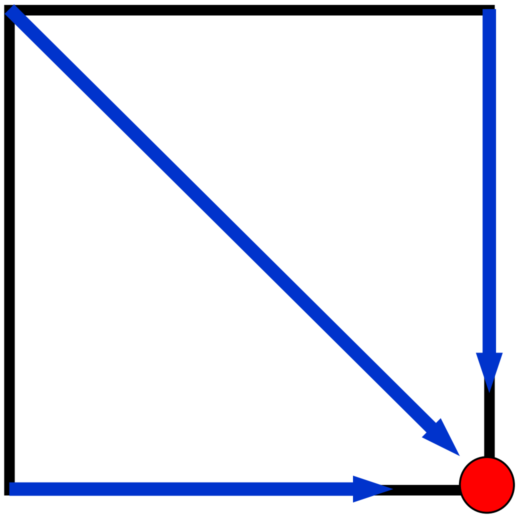

In **2-D**, 3 edges in each unit square

Needleman-Wunsch算法；

$$S_{ij} = \max \text{ of } \begin{cases} S_{i-1,\, j-1} + \sigma(x_i,\, y_j) \\ S_{i-1,\, j} + d \text{ (从上到下)} \\ S_{i,\, j-1} + d \text{ (从左到右)} \end{cases}$$

2-D cell versus 3-D Alignment Cell

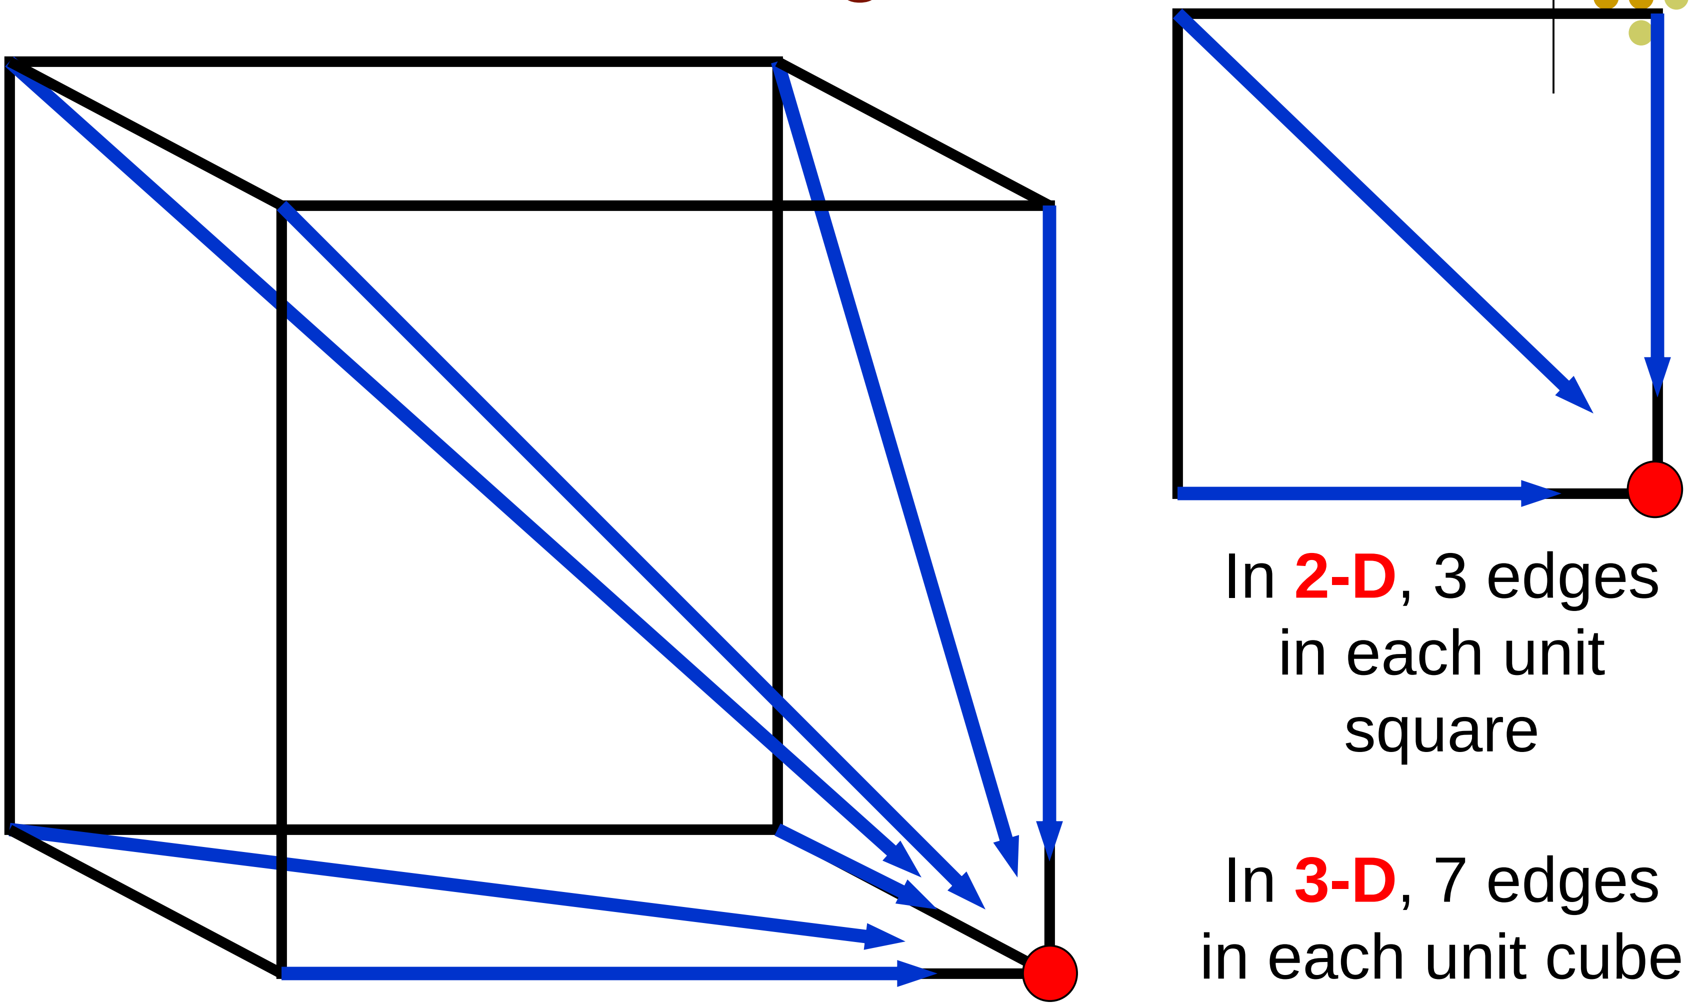

In **2-D**, 3 edges in each unit square

In **3-D**, 7 edges in each unit cube

3-D 比对单元的结构

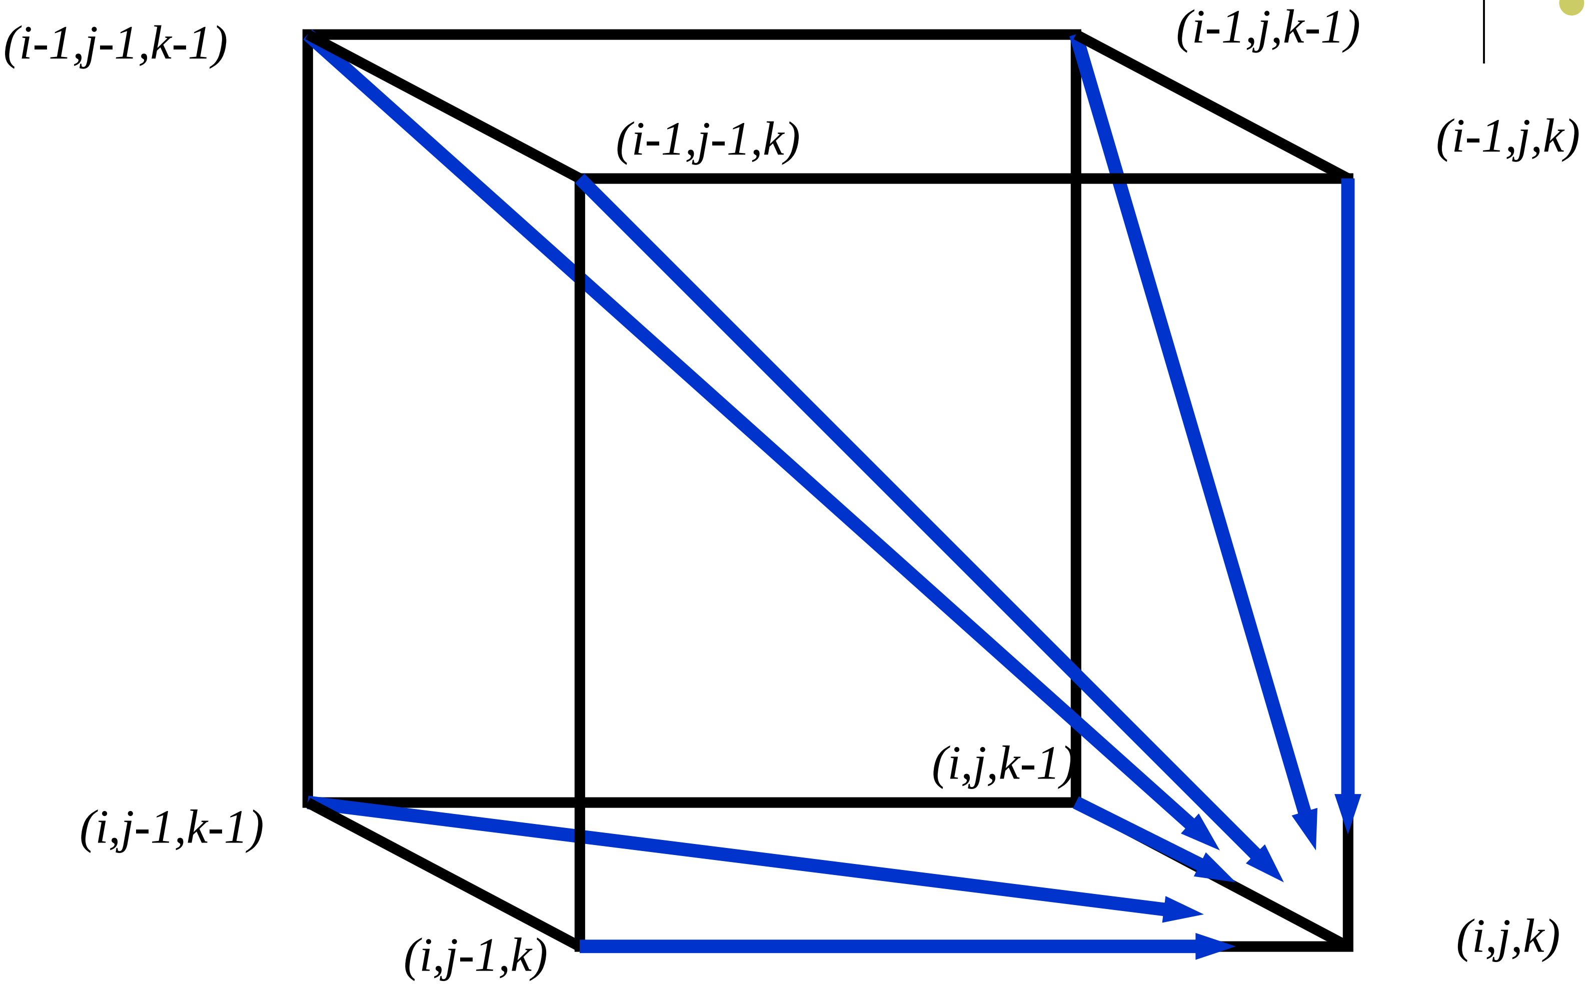

Multiple Alignment: Dynamic Programming

- $$s_{i,j,k} = \max \begin{cases} s_{i-1,j-1,k-1} + \delta(v_i, w_j, u_k) \\ s_{i-1,j-1,k} + \delta(v_i, w_j, \_) \\ s_{i-1,j,k-1} + \delta(v_i, \_, u_k) \\ s_{i,j-1,k-1} + \delta(\_, w_j, u_k) \\ s_{i-1,j,k} + \delta(v_i, \_, \_) \\ s_{i,j-1,k} + \delta(\_, w_j, \_) \\ s_{i,j,k-1} + \delta(\_, \_, u_k) \end{cases}$$
- $\delta(x, y, z)$ 是 3-D 打分矩阵中的元素。

如果比对k条蛋白质序列，记分矩阵是？迭代公式的方程个数是？

多序列比对运行时间

- 对于3条长n的序列，算法的时间复杂度是$7\boldsymbol{n}^3$; $O(\boldsymbol{n}^3)$
- 对于k条序列，时间复杂度是$(2^k-1)(\boldsymbol{n}^k)$; $O(2^k\boldsymbol{n}^k)$
- 结论: 动态规划法虽然可以直接从2维问题推广到高维问题，但是算法是**指数复杂度**的。

- **同步法 不适用于大规模多序列比对!**

自动多序列比对的算法

2.步进法

- 贪婪算法。
- 选择最相似的两条序列构建相似序列，则序列总数变成了k-1。
- 重复这个过程，一直到最后所有序列完成比对。

s1	GTCTGA
s2	GATTCA
s3	GTCAGC
s4	GATATT
s5	GCTCCA

自动多序列比对的算法

s1 GTCTGA
s2 GATTCA
s3 GTCAGC
s4 GATATT
s5 GCTCCA

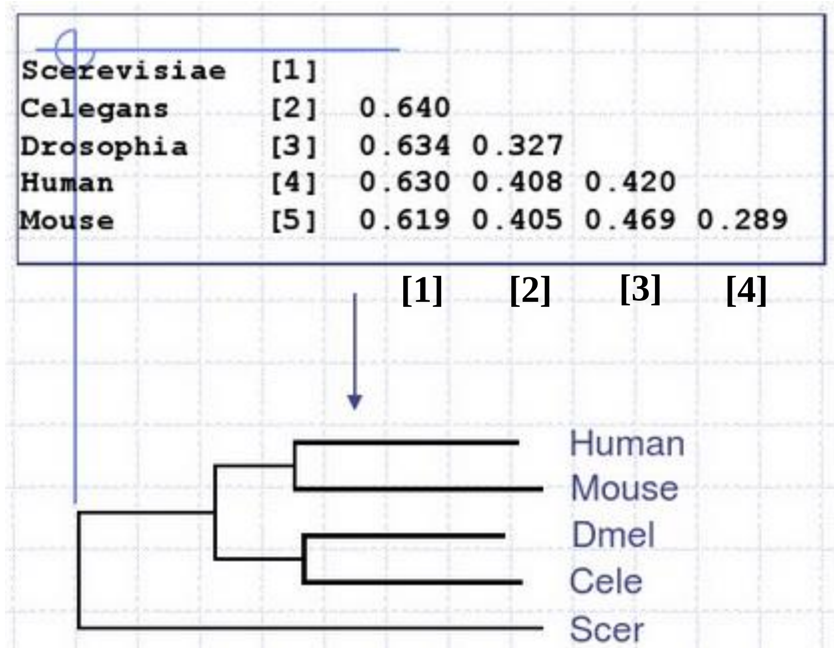

自动多序列比对的算法

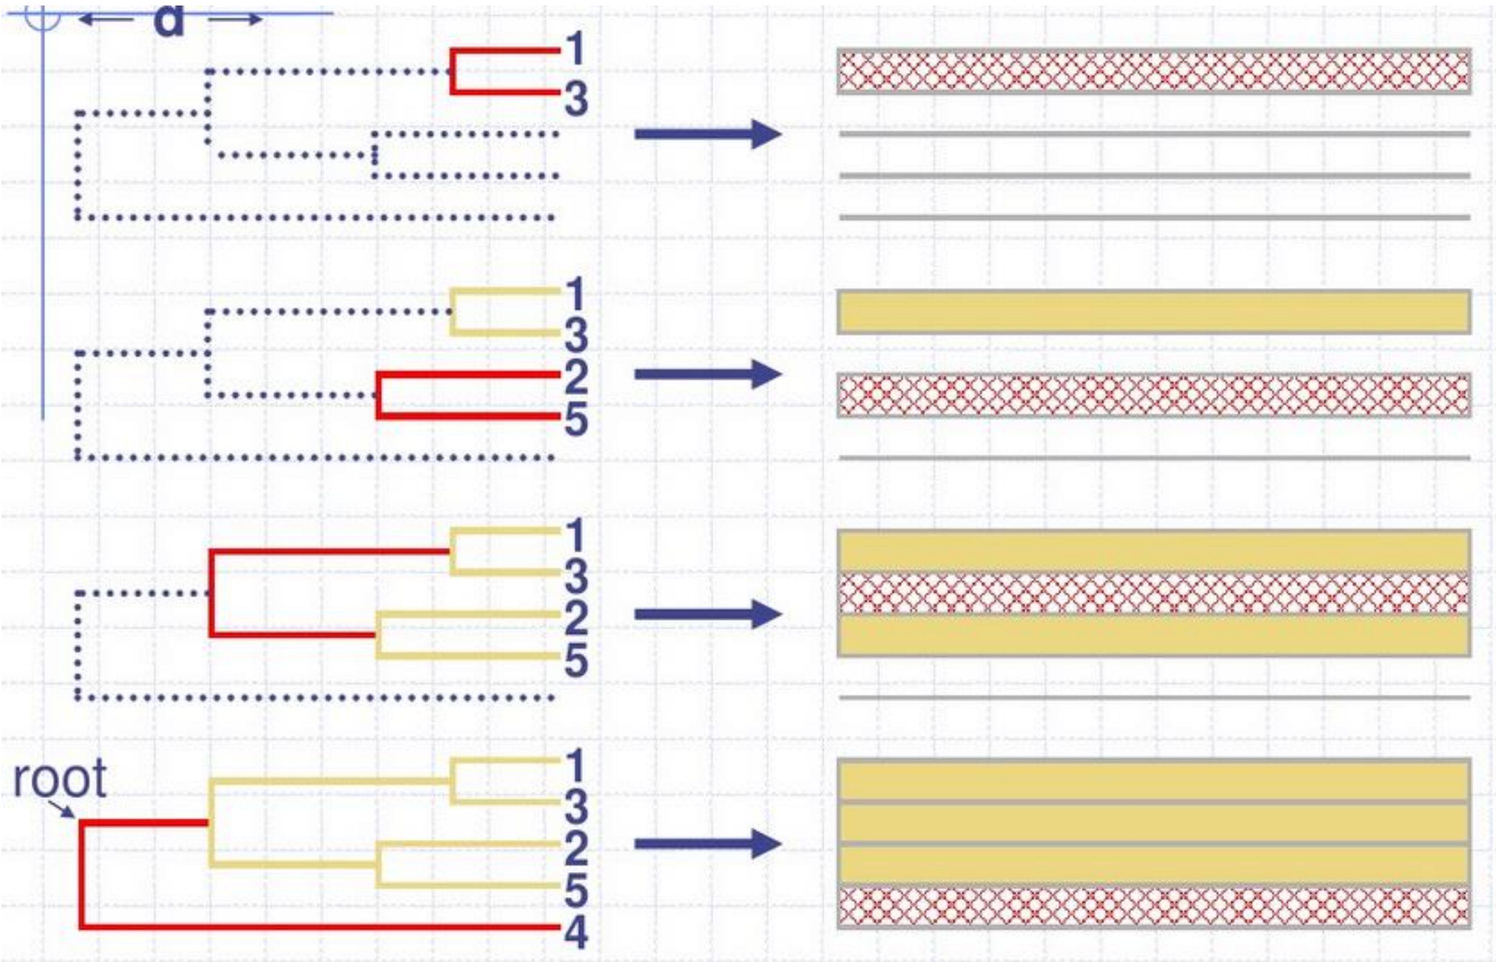

如何合并最近序列？

s1	GTCTGA
s2	GATTCA
s3	GTCAGC
s4	GATATT
s5	GCTCCA

S_1 和S_3 最相似;

s1 GTCTGA

s3 GTCAGC

GTC t/a G a/c

5条“序列”变成4条:

$s_{1,3}$	GTC W G M
s_2	GAT T C A
s_4	GAT A T T
s_5	GCT C C A

代码	
G	
A	
T	(U)
C	
R	(A or G)
Y	(C or T or U)
M	(A or C)
K	(G or T)
S	(C or G)
W	(A or T)
H	(A or C or T)
B	(C or G or T)
V	(A or C or G)
D	(A or G or T)
N	(A or C or G or T)

多序列比对工具

软件名称	特点简介	适用场景
Clustal Omega	快速、适用于大规模比对，支持命令行和Web版本	**蛋白质/核酸序列初步比对**
MAFFT	多种算法选择（FFT、L-INS-i等），速度快且准确性高	**高质量比对、大数据集**
MUSCLE	高准确率，适合中小规模数据	**系统发育分析**
T-Coffee	可以结合多个比对结果，提高一致性	**比对结果可靠性提升**
ProbCons	基于概率一致性的蛋白质比对方法，准确性较高	**蛋白质序列比对（较慢）**
Kalign	基于Wu-Manber算法，运行速度极快	**快速分析（中低准确度）**
DIALIGN-TX	无需全局同源，适合序列部分区域保守的情况	**局部区域对齐**
MSAProbs	基于概率模型 + 并行处理，性能优秀	**蛋白质序列高精度对齐**

多序列比对工具 －clustal

Clustal是一个单机版的基于渐进比对的多序列比对工具，由Higgins D.G. 等开发。

有应用于多种操作系统平台的版本，包括linux版，DOS版的clustlw，windows版本的clustalx等。

Clustal简介

- 算法：渐进比对方法

1. 将多个序列两两比对构建**距离矩阵**，反应序列之间两两关系；
2. 根据距离矩阵生成**系统进化指导树**；
3. 从**最紧密**的两条序列开始，**逐步引入临近的序列**并不断重新构建比对，直到所有序列都被加入为止。

Clustalx的工作界面（多序列比对模式）

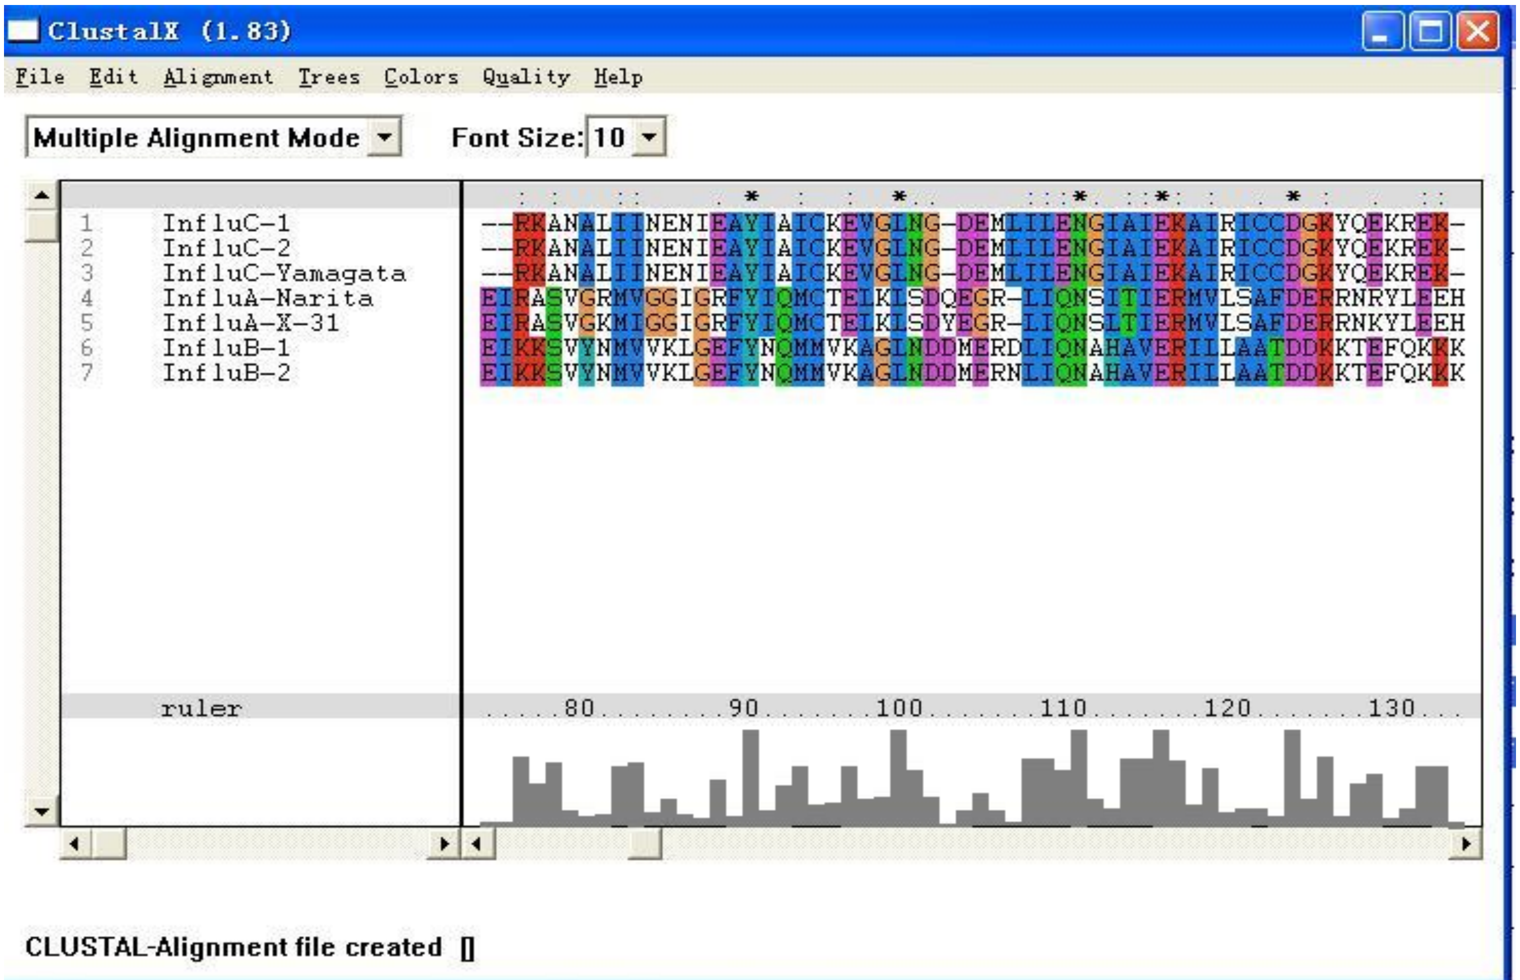

Clustalx的工作界面
（剖面(profile)比对模式）

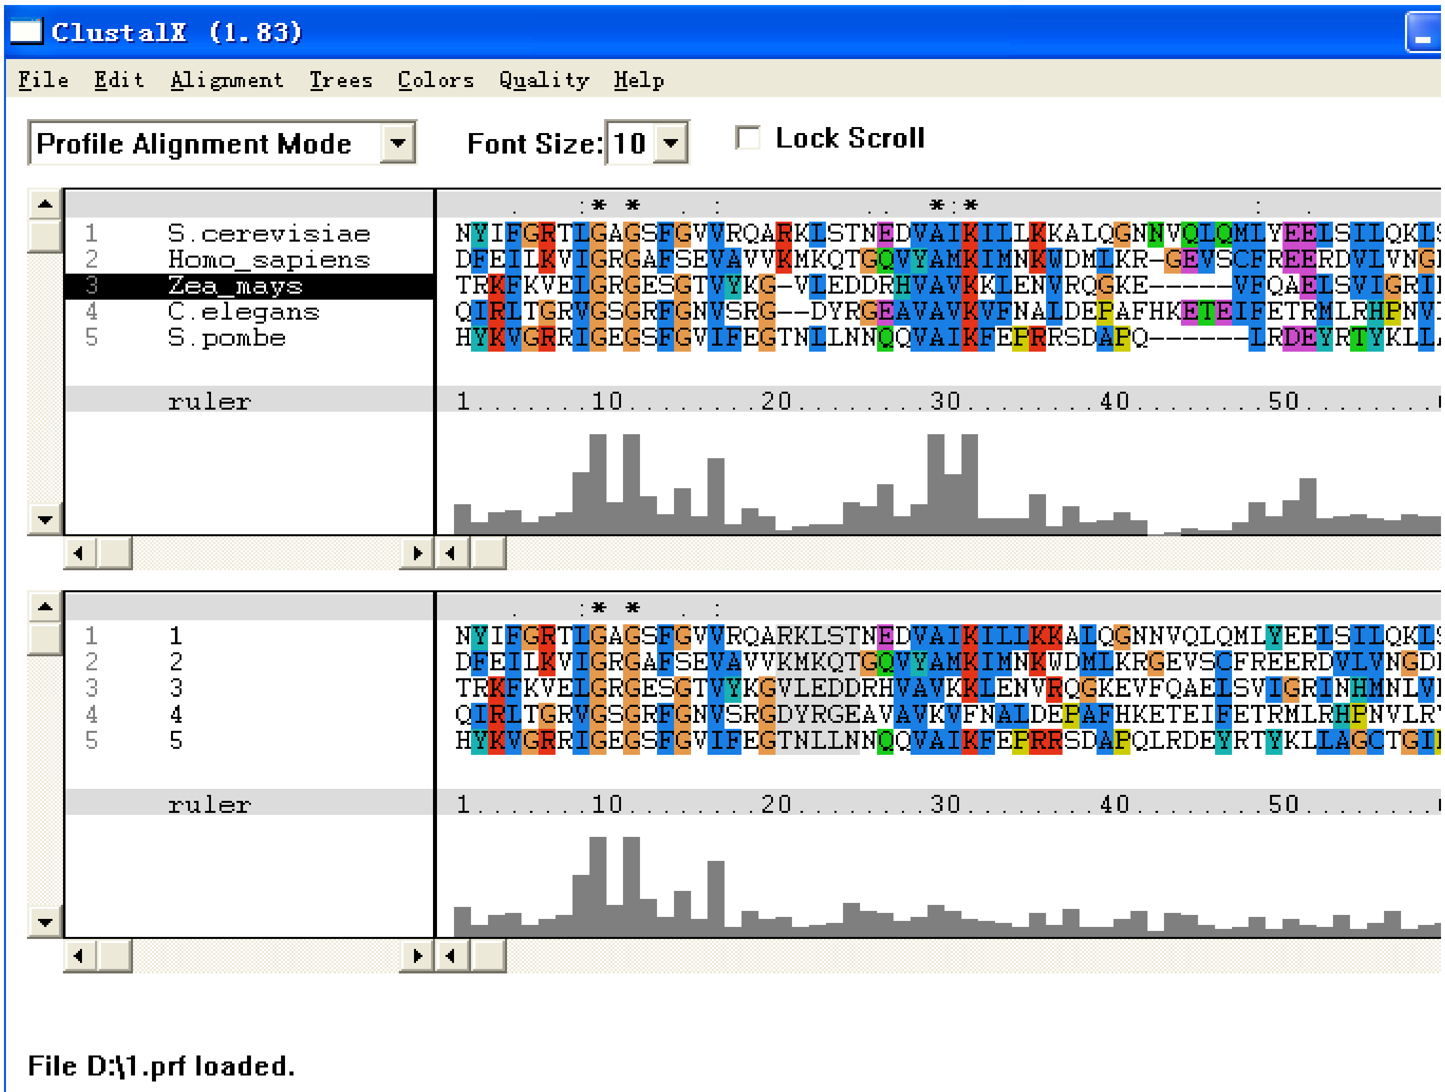

Clustal的工作原理

Clustal输入多个序列

快速的序列两两比对，计算序列间的距离，获得一个距离矩阵。

邻接法(NJ)构建一个树（引导树）

根据引导树，渐进比对多个序列。

Clustal的应用

1.输入输出格式。

输入序列的格式比较灵活，可以是前面介绍过的**FASTA**格式，还可以是PIR、SWISS-PROT、GDE、Clustal、GCG/MSF、RSF等格式。

输出格式也可以选择，有**ALN**、GCG、PHYLIP和NEXUS等，用户可以根据自己的需要选择合适的输出格式。

Clustal的应用

2.两种工作模式。

a.多序列比对模式。

b.剖面(profile)比对模式。

3.一个实际的例子。

多序列比对实例

输入文件的格式(fasta)：

>KCC2_YEAST
NYIFGRTLGAGSFGVVRQARKLSTN……
>DMK_HUMAN
DFEILKVIGRGAFSEVAVVKMKQTGQVYAMKIMNK…….
>KPRO_MAIZE
TRKFKVELGRGESGTVYKGVLEDDRHVAVKKLEN……
>DAF1_CAEEL
QIRLTGRVGSGRFGNVSRGDYRGEAVAVKVFNALD……
>1CSN
HYKVGRRIGEGSFGVIFEGTNLLNN……

第一步：输入序列文件。

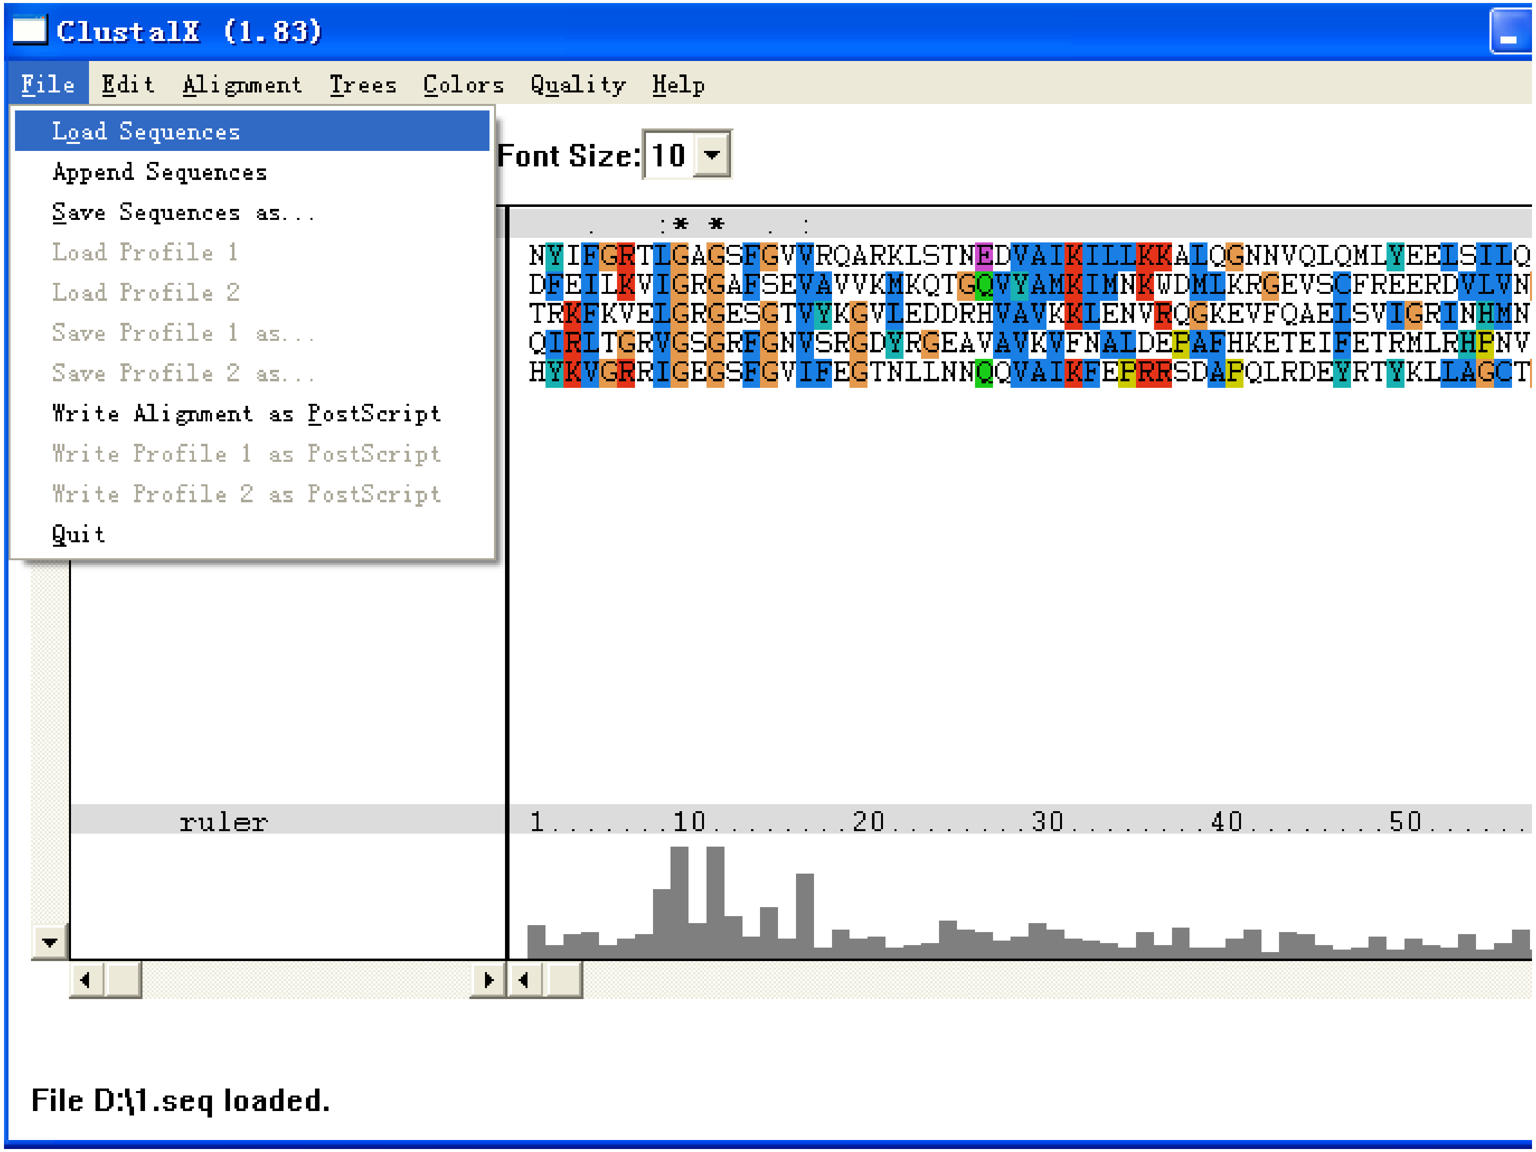
ClustalX (1.83)
File
Edit
Alignment
Trees
Colors
Quality
Help
Load Sequences
Append Sequences
Save Sequences as...
Load Profile 1
Load Profile 2
Save Profile 1 as...
Save Profile 2 as...
Write Alignment as PostScript
Write Profile 1 as PostScript
Write Profile 2 as PostScript
Quit
Font Size: 10
ruler
1.......10.........20.........30.........40.........50.....
File D:\1.seq loaded.

第二步：设定比对的一些参数。

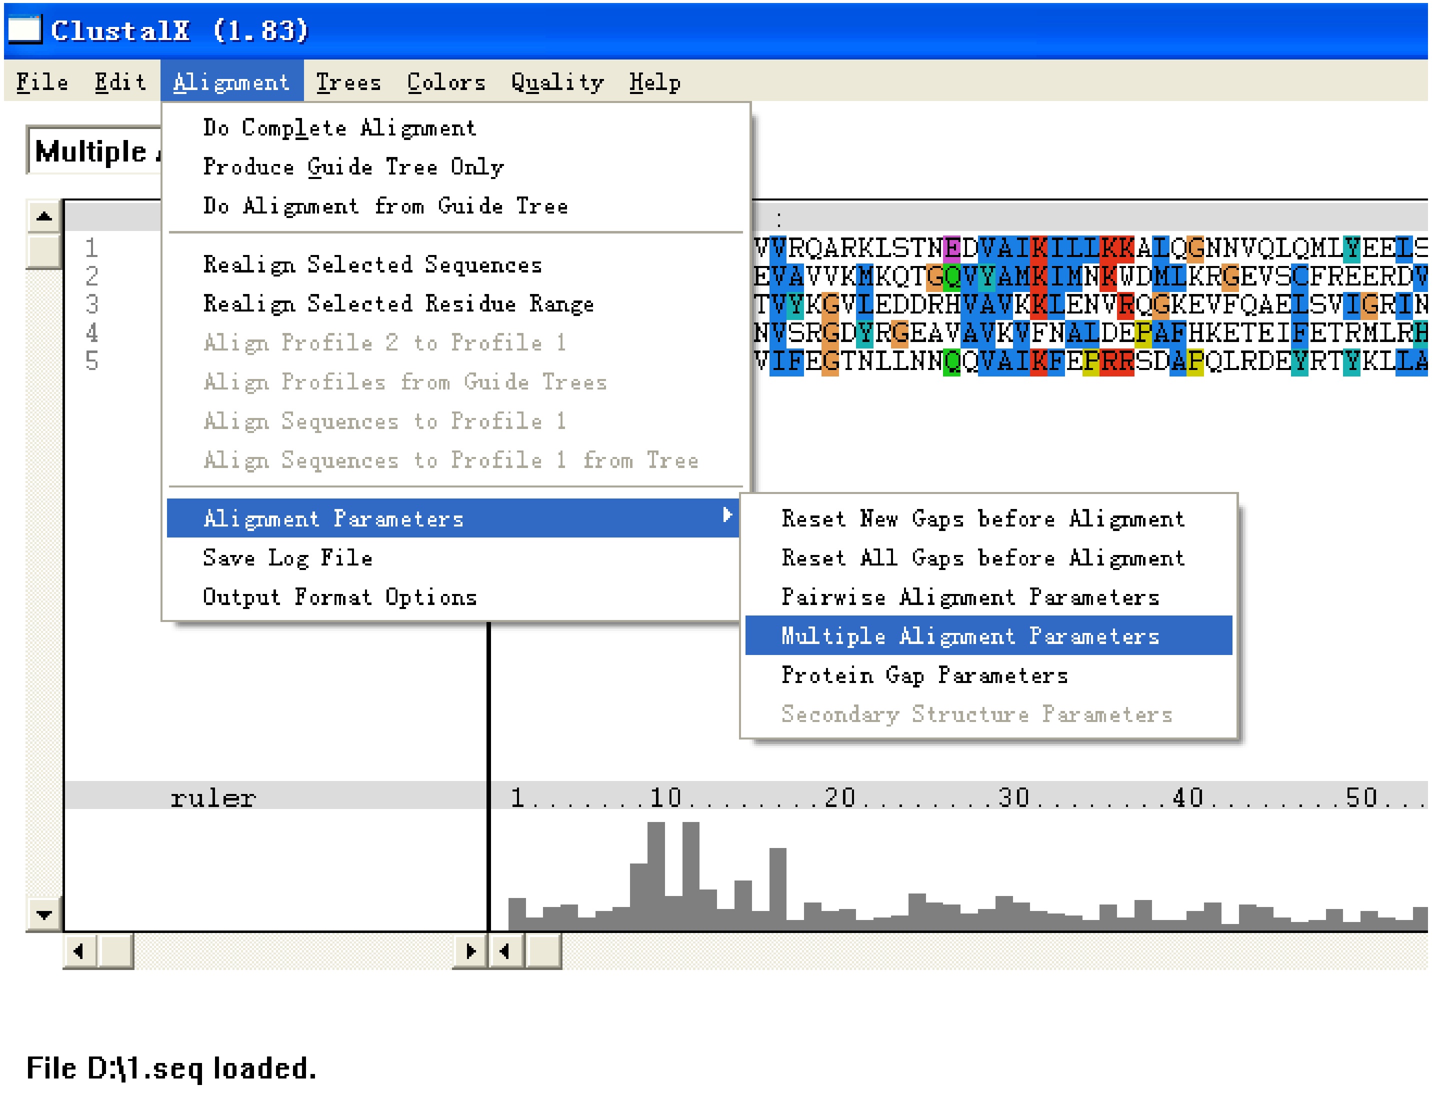

参数设定窗口。

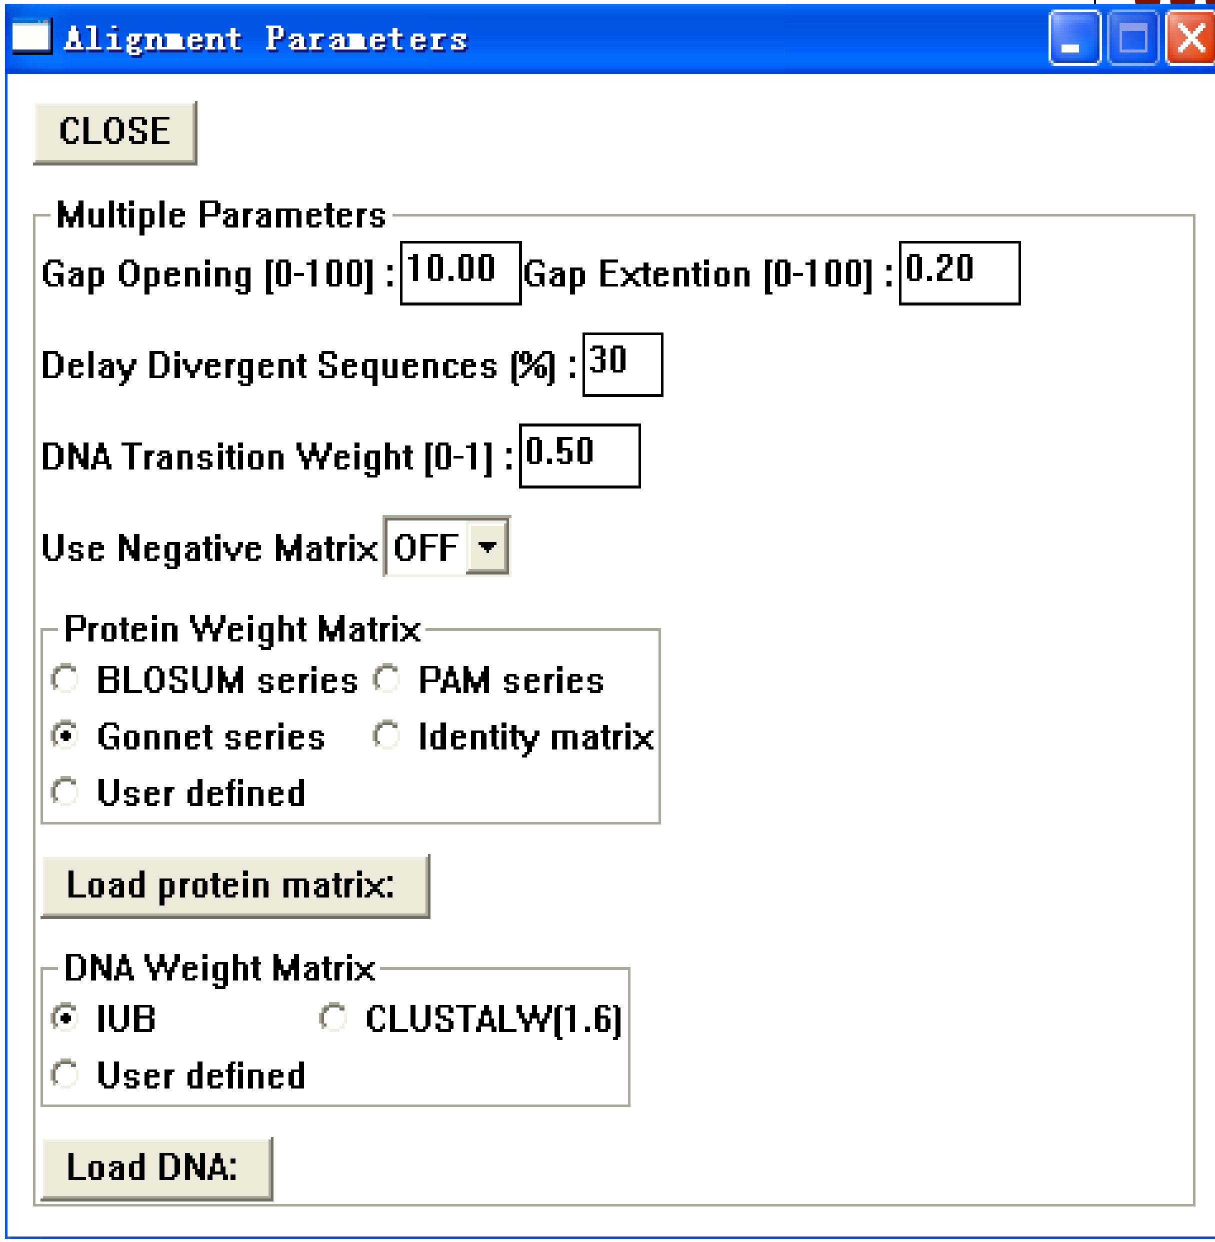
Alignment Parameters
CLOSE
Multiple Parameters
Gap Opening [0-100] :
10.00
Gap Extention [0-100] :
0.20
Delay Divergent Sequences (%) :
30
DNA Transition Weight [0-1] :
0.50
Use Negative Matrix
OFF
Protein Weight Matrix
BLOSUM series
PAM series
Gonnet series
Identity matrix
User defined
Load protein matrix:
DNA Weight Matrix
IUB
CLUSTALW(1.6)
User defined
Load DNA:

第三步：开始序列比对。

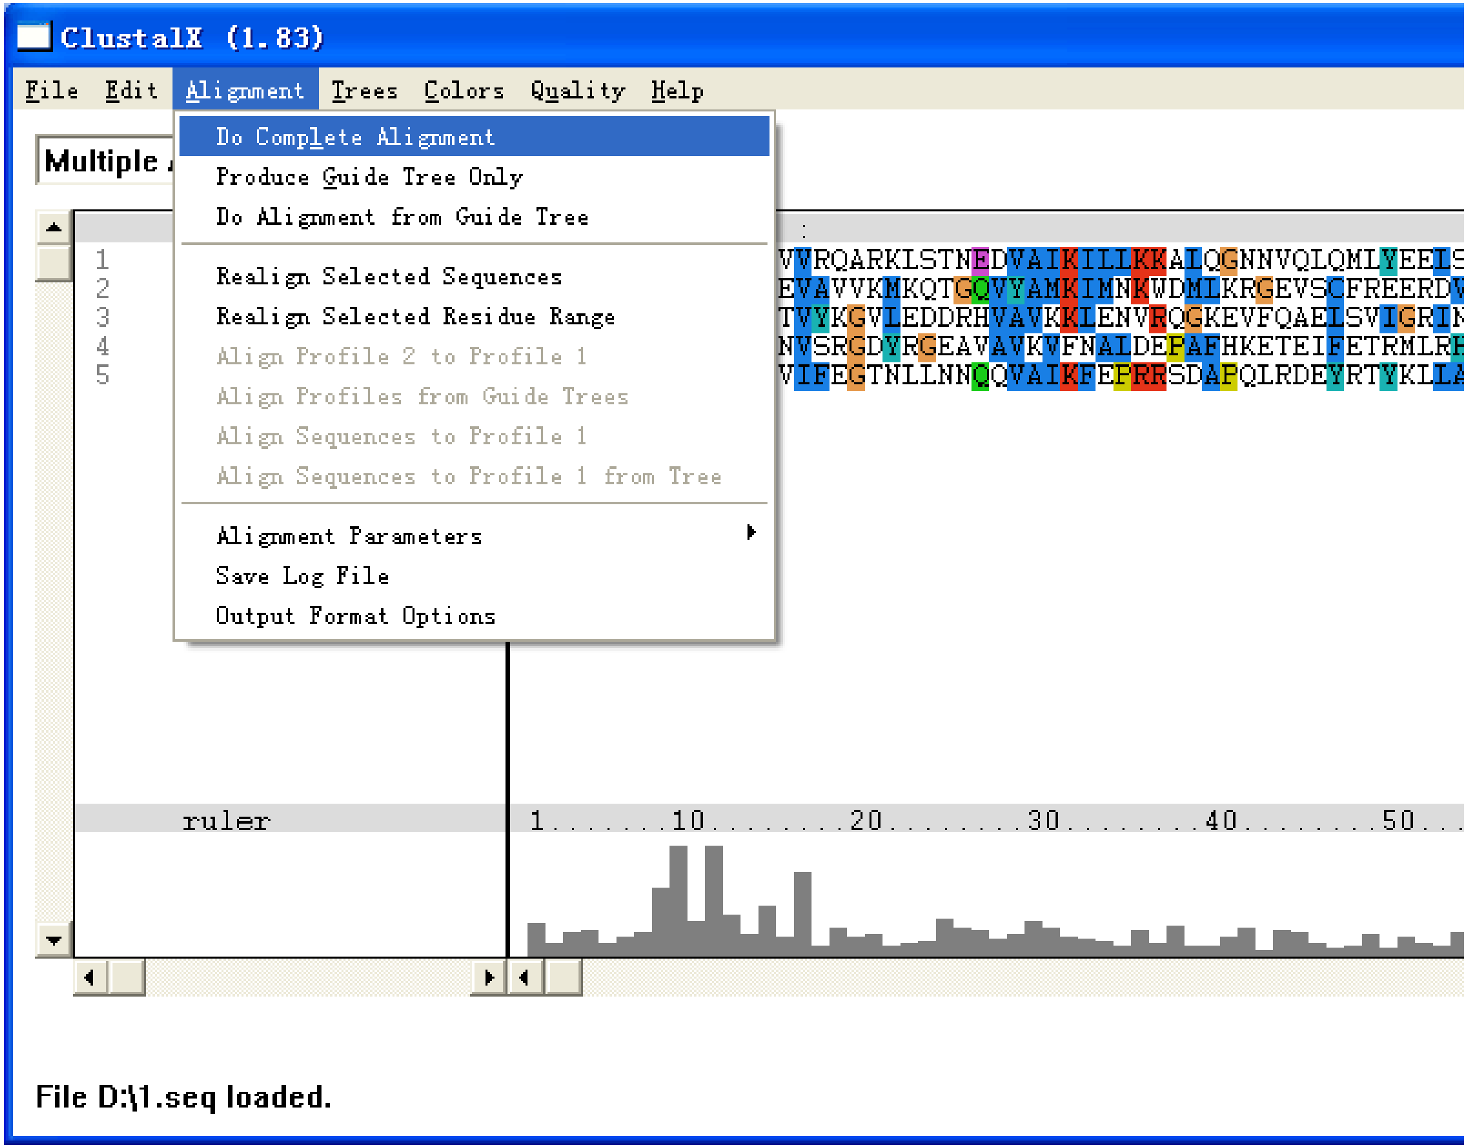
ClustalX (1.83)
File Edit Alignment Trees Colors Quality Help
Multiple
Do Complete Alignment
Produce Guide Tree Only
Do Alignment from Guide Tree
Realign Selected Sequences
Realign Selected Residue Range
Align Profile 2 to Profile 1
Align Profiles from Guide Trees
Align Sequences to Profile 1
Align Sequences to Profile 1 from Tree
Alignment Parameters
Save Log File
Output Format Options
1
2
3
4
5
VVRQARKLSTNEDVAIKILIKKALQGNNVQLQMLYEELS
EVAVVKMKQTGQVYAMKIMNKWDMLKRGEVSCFREERDV
TVYKGVLEDDRHVAVKKLENVRQGKEVFQAELSVIGRIN
NVSRGDYRGEAVAVKVFNALDEPAFHKETEIFETRMLRH
VIFEGTNLLNNQQVAIKFEPRRSDAPQLRDEYRTYKLLA
ruler
1.......10.........20.........30.........40.........50...
File D:\1.seq loaded.

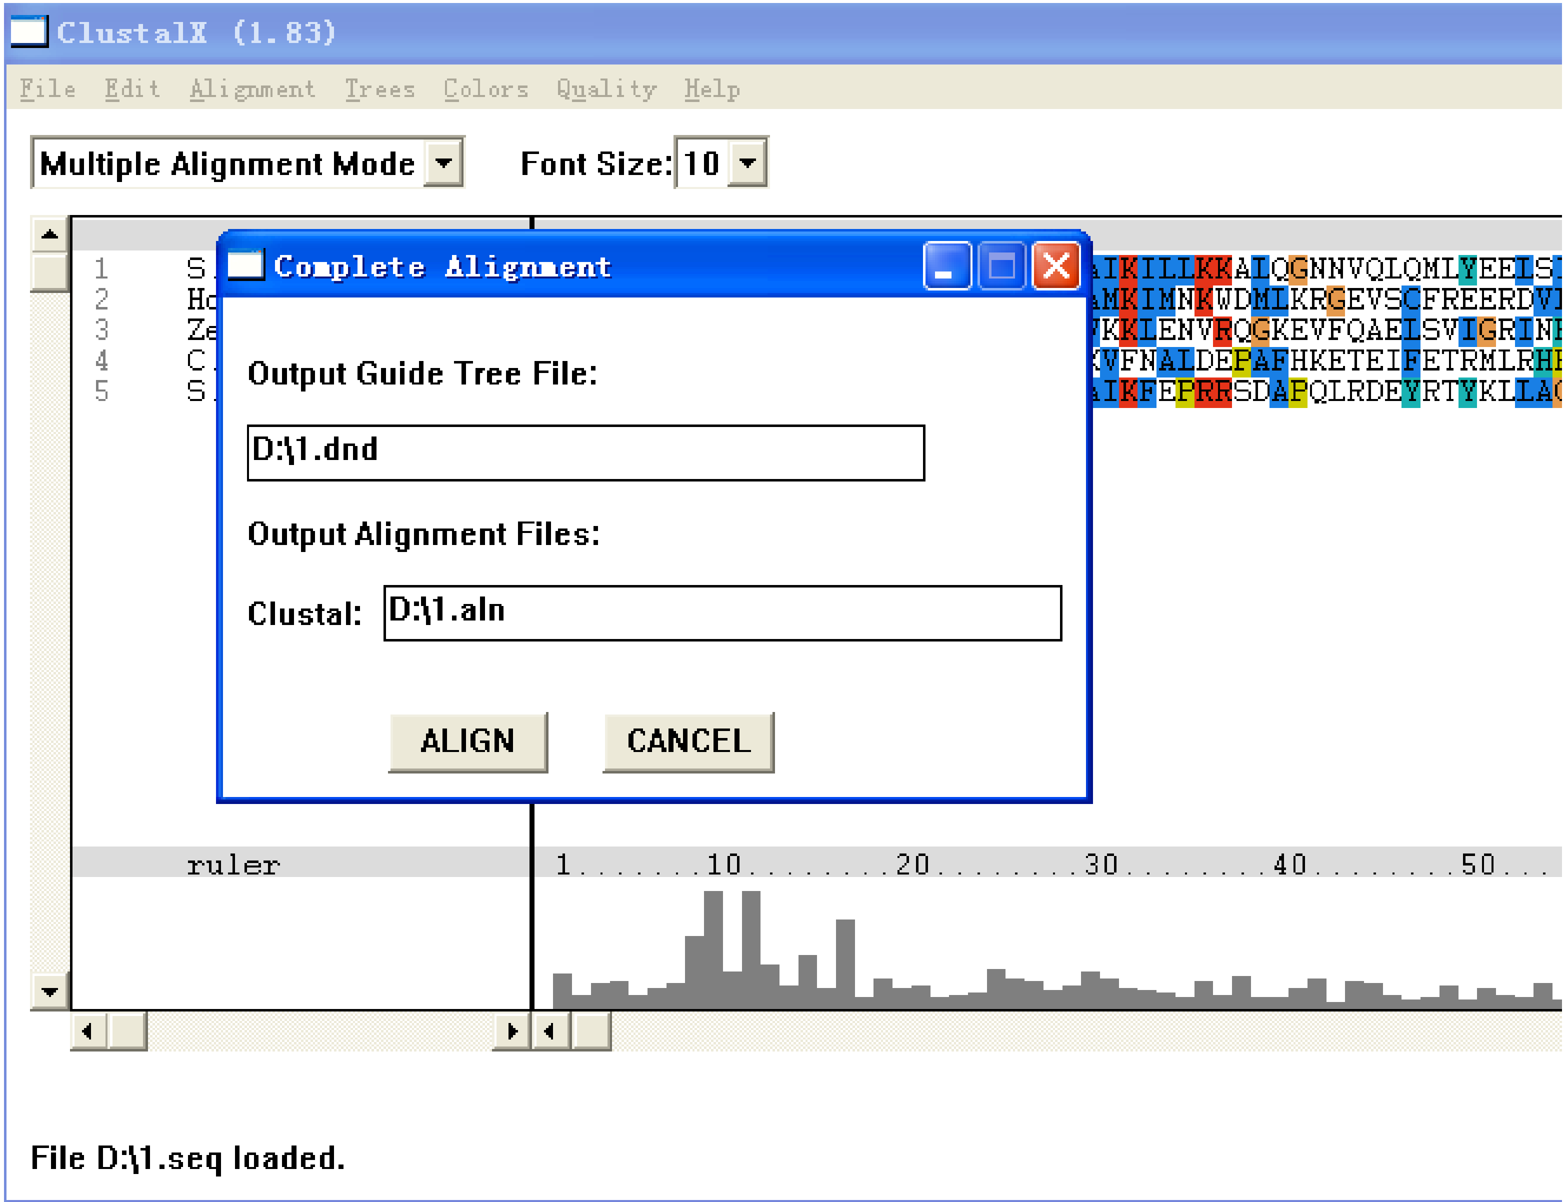

ClustalX (1.83)
File Edit Alignment Trees Colors Quality Help
Multiple Alignment Mode
Font Size: 10
Complete Alignment
Output Guide Tree File:
D:\1.dnd
Output Alignment Files:
Clustal:
D:\1.aln
ALIGN
CANCEL
ruler
1.......10........20........30........40........50...
File D:\1.seq loaded.

第四步：比对完成，选择保存结果文件的格式

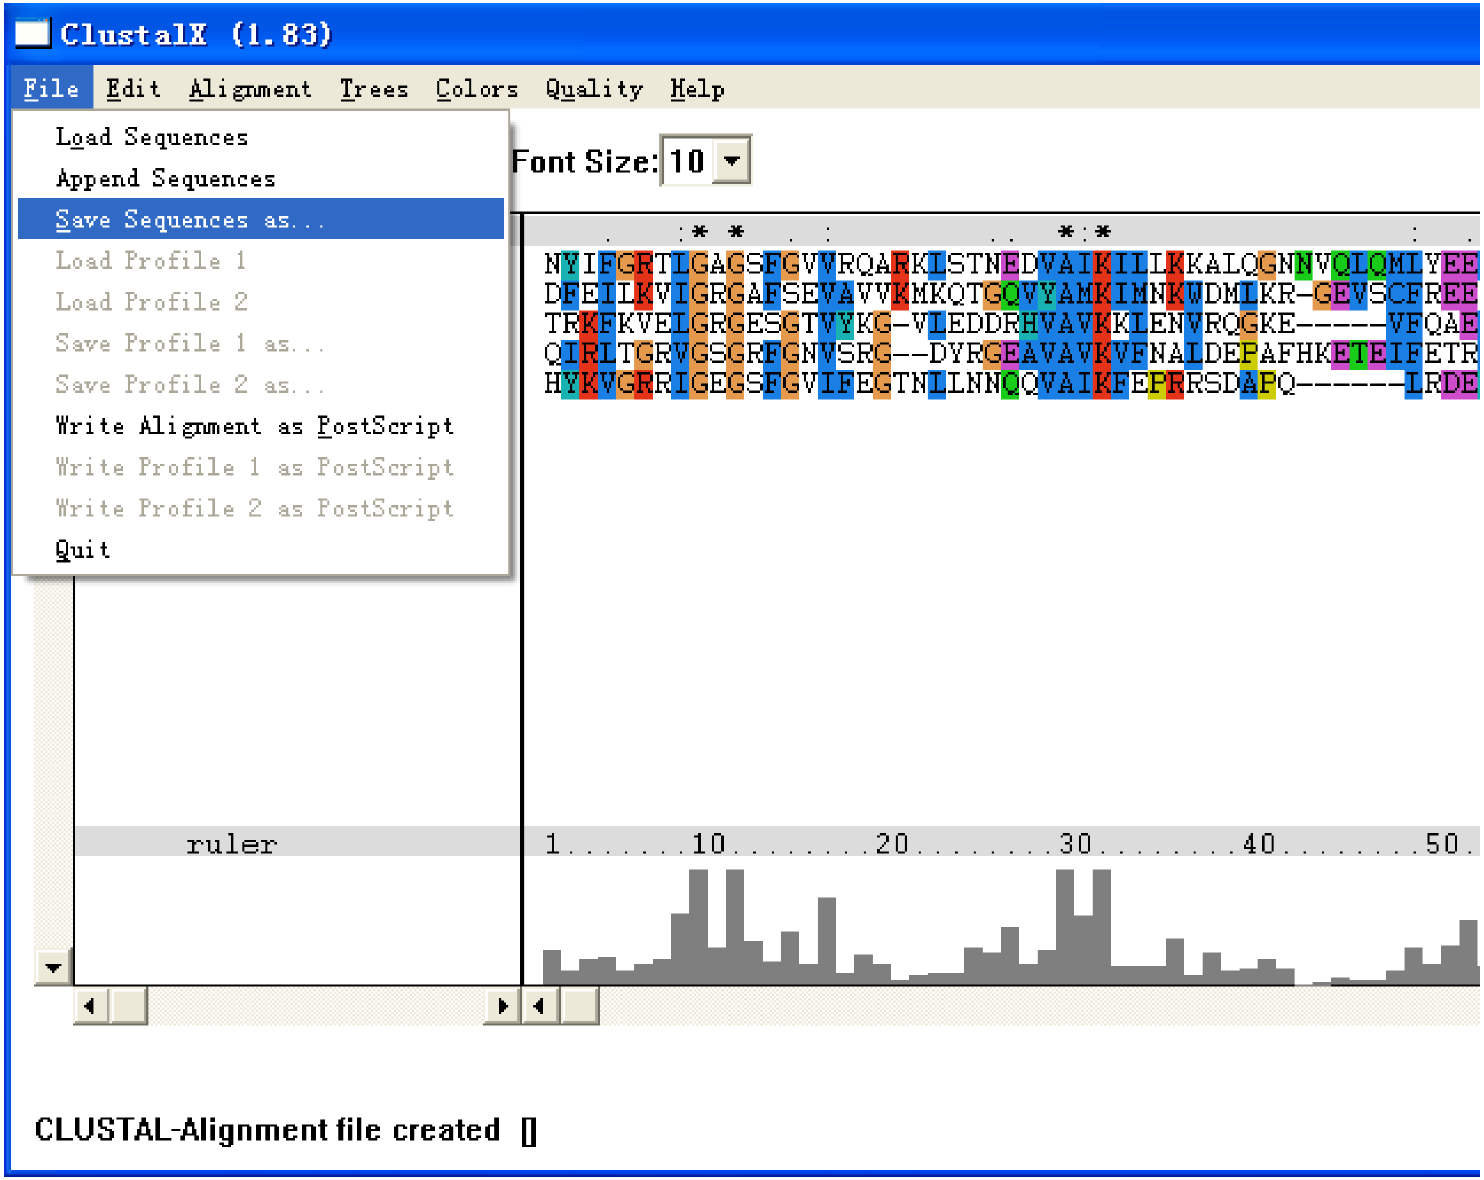

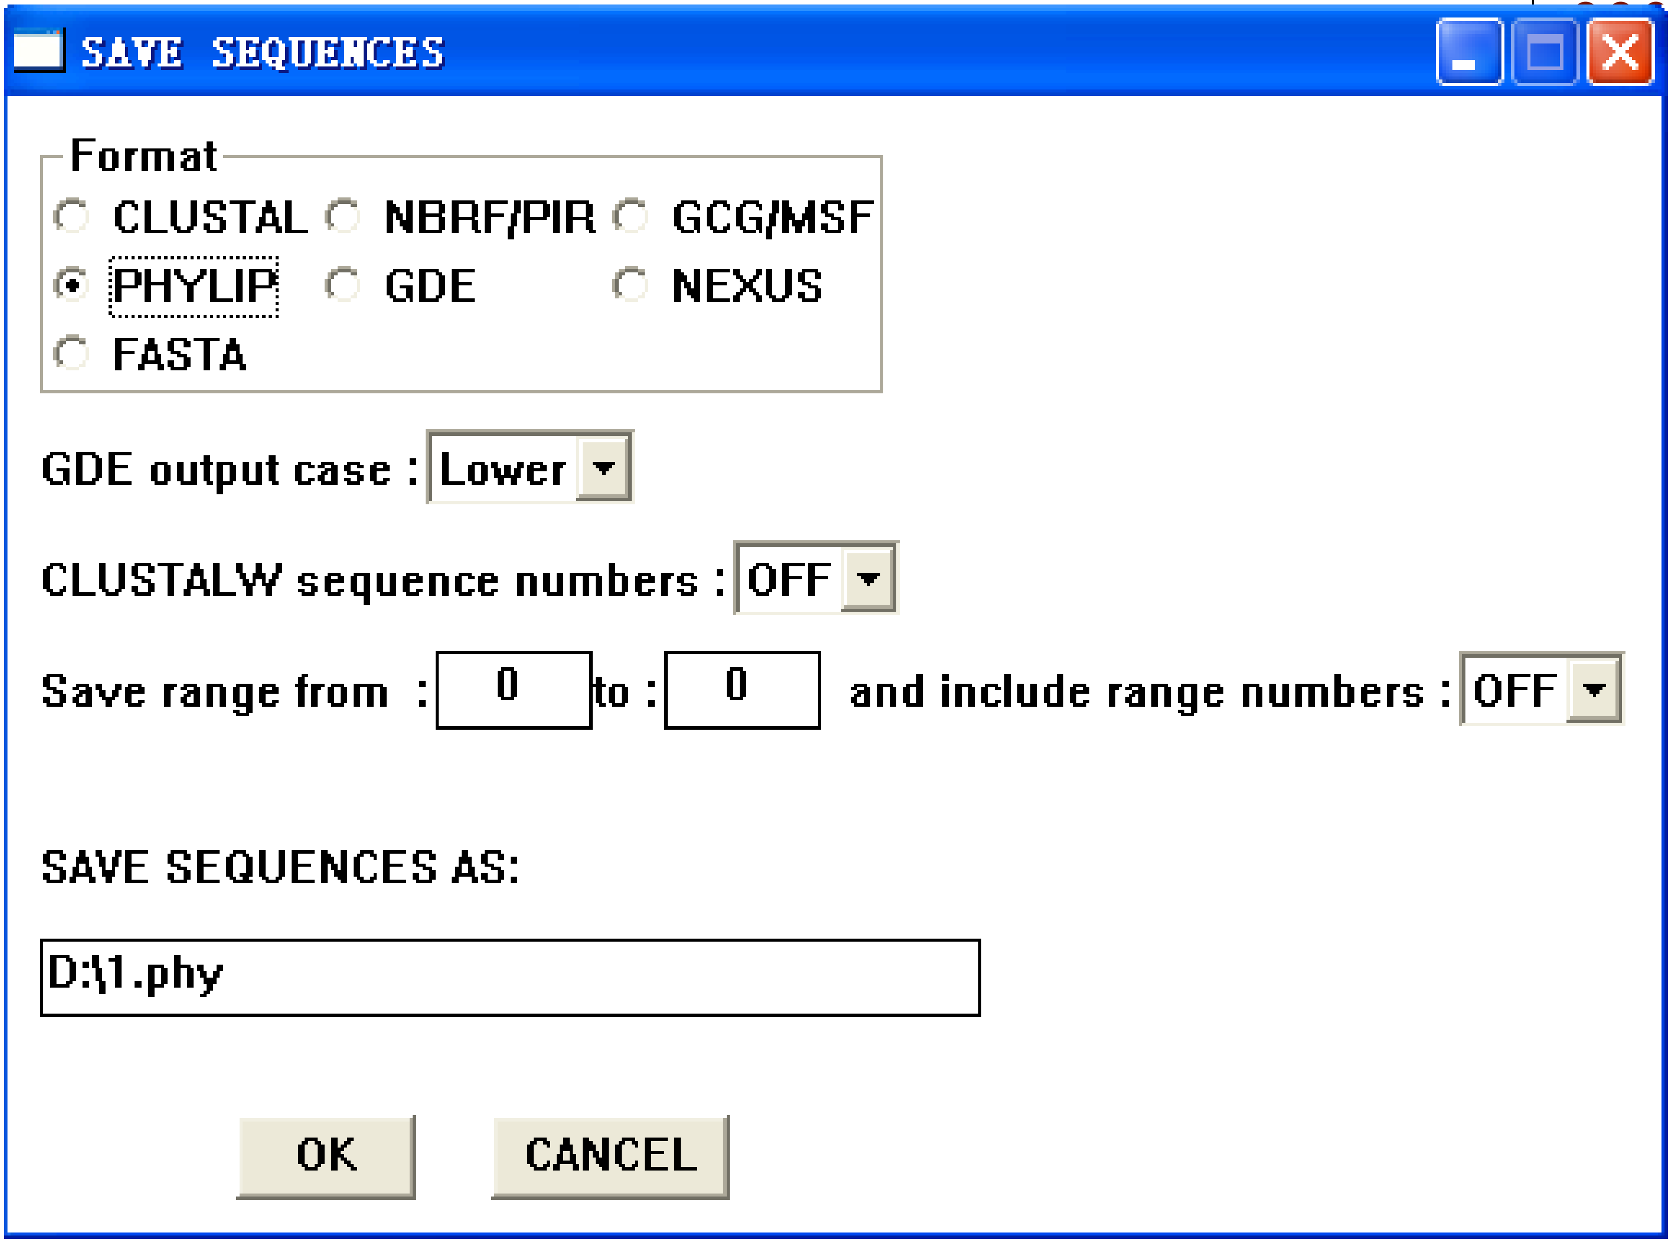
SAVE SEQUENCES
Format
CLUSTAL
NBRF/PIR
GCG/MSF
PHYLIP
GDE
NEXUS
FASTA
GDE output case :
Lower
CLUSTALW sequence numbers :
OFF
Save range from :
0
to :
0
and include range numbers :
OFF
SAVE SEQUENCES AS:
D:\1.phy
OK
CANCEL

在线的clustalw分析

1.EBI提供的在线clustalw服务

http://www.ebi.ac.uk/clustalw/

EBI提供的在线Clustalw服务

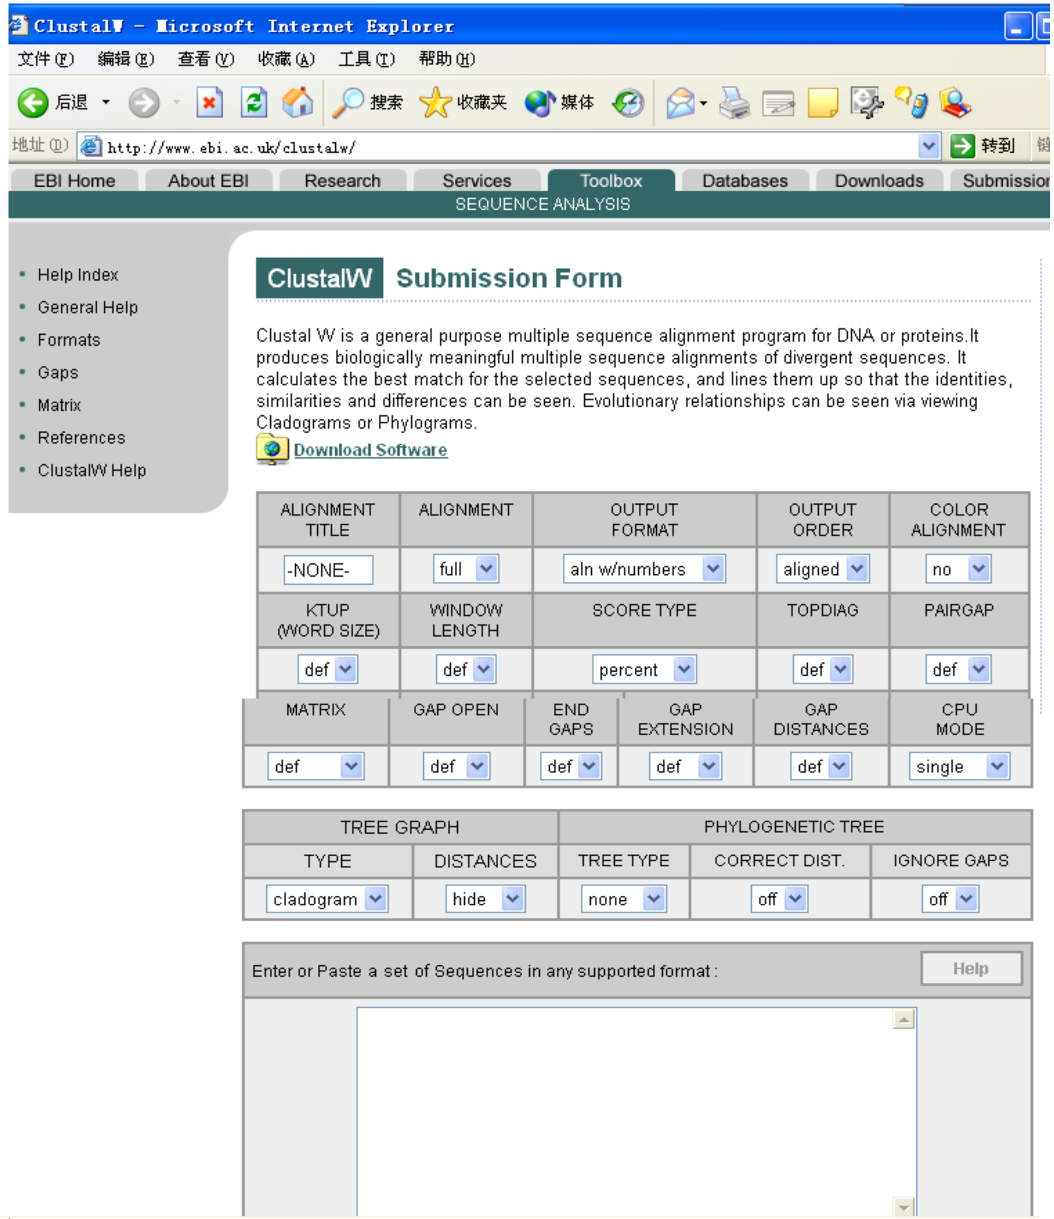

更为详细的教程

可以在这里得到更多关于clustal的帮助：

http://www-igbmc.u-strasbg.fr/BioInfo/ClustalX/Top.html