

基因识别

AAAAGCCTTATTCACTTCCTTTTTGTTCCCCAAATTCTCGAAATCGAAAAAGACGAGACTTTTAA
CACTCAGACCTAAACCAACACTCTTCCTCTTTCTATCTCTCTCTCGCCGATCGGAAGCAGATTT
TTCTCAAAGGATGGATTCAACGAAGCTTAGTGAGCTAAAGGTCTTCATCGATCAATGCAAGT
CTGACCCTTCCCTTCTCACTACTCCTTCACTCTCCTTCTTCCGTGACTATCTCGAGAGGTATAT
ATTTTTTTGTTTGGTTCAATTGAATTCGTTTGTGTGTTTTGCAGAAGAGTTTGTTTTTGATTTGA
TTGTTTCTGTTTAACAGAGGAGTTTCGTAGTGGAAGAGAGTGATGATGATATGGATGAAACTG
AAGAAGTAAAACCGAAAGTGGAGGAAGAAGAAGAAGAGGATGAGATTGTTGAATCTGATGTA
GAGCTTGAAGGAGACACTGTTGAGCCTGATAATGATCCTCCTCAGAAGGTACCATGATGACTA
AGCAAAACCTTAGCTTTTGATTTTACTAATTTCTGTCTGATTGTGTGTTTCTGACTCTCTTGGTT
TCGATACAGCTAGTGTCTACATTAAGTTGAAGAAGCCAAACGCTGCTATTCGAGATGCAAACG
CAGCATTGGAGGTACAGTGGTCTACAATTTTCCTTGAGAATTTTGTTTTATGGTGATGATATTCA
ATCGTTTTGTGTTTATGATCAGAGATTAAGCCTGATTCTGCCAAGCGGATACAAGTCACGAGGTA
TGGCTCGTGCCATGCTTGGAGAATGGTCAGAGCTGCAAAGACCTTCACCTTGCATCTACG
ATAGACTATGATGAGGAATTAGTGCTCTTCTCAAAGGTATGCTGTGTTTGTCTATATGTTT
AATCACTTTTGATTCATTAACAATGCATAAGCGTGATTCTTATACAAACATTTTTTTTGAAATTTGT
AGGTTGAACCTAATGCACATAAGCTTGAGGAGCACCGTAGAAAGTATGACAGATTACGTAAGG
AAAGAGAGGACAAAAAGGCTGAACGGGATAGATTACGTCGCCGTGCTGAAGCACAGGTAGC
TTCATAGACCATGAAATCAATCAGAATAATATTTTGATAACATTAGTCAGTTTTTGATTGACCTTAT
CACTTAGCTATAGACATGGGTTTTGTTTATATAATGTTGGGCTTATCCATATCTCTTTTTCTGTAG
ATCCTGAGCTAATGACGGCATTTAGCGACCCTGAAGTCATGGCTGCTCTTCAAGATGGTATGA
TGACTCAGTTTAAAGTTGCAGTTTATTAATGTTTTTTGAATATTTTTTCGAGTCTTGAATGTTGTTT
GAATGCTATAACAGTGATGAAGAACCCTGCGAATCTAGCGAAGCATCAGGCGAATCCGAAGG
TGGCTCCCGTGATTGCAAAGATGATGGGCAAATTTGCAGGACCTCAGTAAACAAAACAAGAA
GCTTGCTTTTCTTTGCCAATTTCTGTGTTTAATTGCGTGAGATAAGAGATATGTTGGAGAACTT
TTGTTTTCTTTTATGTTGTCGTTGCAGAGGAACTTTAACAGGAACAAAACCTTTTTCTCTTCGT
TAGTAATCTACCCTCTTCTCGTTTTTCACTTCCTGAGTTAGAAGATTTATATTGAAAGATTCGTAT
AAGTATAACACTTCCAACATTGTTTTTTATGCGTCGTGAGA

AAAAGCCTTATTCACTTCCTTTTGTTCCCCAAATTCTCGAAATCGAAAAAGACGAGACTTTTAA
CACTCAGACCTAAACCAACACTCTTCCTCTTTCTATCTCTCTCGCCGATCGGAAGCAGATT
TTCTCAAAGGATGGATTCAACGAAGCTTAGTGAGCTAAAGGTCTTCATCGATCAATGCAAGT
CTGACCCTTCCCTTCTCACTACTCCTTCACTCTCCTTCTTCCGTGACTATCTCGAGAGGTATAT
ATTTTTTTGTTTGGTTCAATTGAATTCGTTTGTGTGTTTGCAGAAGAGTTTGTTTTTGATTGA
TTGTTTCTGTTTAACAGAGGAGTTTCGTAGTGGAAGAGAGTGATGATGATATGGATGAACTG
AAGAAGTAAAACCGAAAGTGGAGGAAGAAGAAGAAGAGGATGAGATTGTTGAATCTGATGTA
GAGCTTGAAGGAGACACTGTTGAGCCTGATAATGATCCTCCTCAGAAGGTACCATGATGACTA
AGCAAAACCTTAGCTTTTGATTTTACTAATTTCTGTCTGATTGTGTGTTTCTGACTCTCTTGGTT
TCGATACAGCTAGTGTCTACATTAAGTTGAAGAAGCCAAACGCTGCTATTCGAGATGCAAACG
CAGCATTGGAGGTACAGTGGTCTACAAATTTCTTGAGAATTTTGTATTTATGGTGATGATATTCA
ATCGTTTTGTGTTTATGATCACAGATTAAACCTGATTCTGCCAAGGGATACAAGTCACGAGGTA
TGGCTCGTGCCATGCTTGGAGAATGGGCAGAGGCTGCAAAGACCTTCACCTTGCATCTACG
ATAGACTATGATGAGGAAATTAGTGCTGTTCTCAAAAAGGTATGCATGTGTTTGTCTATATGTT
AATCACTTTTGATTCATTAACAATGCATAAGCGTGATTCTTATACAAACATTTTTTTGAAATTTGT
AGGTTGAACCTAATGCACATAAGCTTGAGGAGCACCGTAGAAAGTATGACAGATTACGTAAGG
AAAGAGAGGACAAAAAGGCTGAACGGGATAGATTACGTCGCCGTGCTGAAGCACAGGTAGC
TTCATAGACCATGAAATCAATCAGAATAATATTTTGATAACATTAGTCAGTTTTGTATTGACCTTAT
CACTTAGCTATAGACATGGGTTTTGTTTATATAATGTTGGGCTTATCCATATCTCTTTTTCTGTAG
ATCCTGAGCTAATGACGGCATTTAGCGACCCTGAAGTCATGGCTGCTCTTCAAGATGGTATGA
TGACTCAGTTTAAAGTTGCAGTTTATTAATGTTTTTTGAATATTTTTTCGAGTCTTGAATGTTGTTT
GAATGCTATAACAGTTGATGAAGAACCCTGCGAATCTAGCGAAGCATCAGGCGAATCCGAAGG
TGGCTCCCGTGATTGCAAAGATGATGGGCAAATTTGCAGGACCTCAGTAAACAAAACAAGAA
GCTTGCTTTTCTTTGCCAATTTCTGTGTTTAATTGCGTGAGATAAGAGATATGTTGGAGAACTT
TTGTTTTCTTTTATGTTGTCGTTGCAGAGGAACTTTAACAGGAACAAAACCTTTTTCTCTTCGT
TAGTAATCTACCCTCTTCTCGTTTTTCACTTCCTGAGTTAGAAGATTTATATTGAAAGATTCGTAT
AAGTATAACACTTCCAACATTGTTTTTATGCGTCGTGAGA


Gene!

基因识别


基因识别——使用计算机手段识别DNA序列上的具有生物学特征的片段，其对象主要是蛋白质**编码基因**，也包括其他具有一定生物学功能的因子，如RNA、MicroRNA基因等一些**非编码基因**，基因识别是生物信息学领域里的一个重要研究内容。

基因结构回顾

原核基因




真核基因



原核基因识别

原核基因基本结构识别

原核基因是DNA分子的一个片段，具有连续编码的结构特征。



原核基因识别——重点在于识别编码区域。

阅读框 Reading frames

- 对于核酸序列（不考虑互补链），根据密码子的起始位置，可以按照三种方式进行解释。

例如，序列ATTTCGATCGCAA


(1) ATT CGA TCG CAA

(2) TTC GAT CGC AAN

(3) TCG ATC GCA ANN

- 这三种阅读顺序称为阅读框（reading frames）

- 开放阅读框（**open reading frame, ORF**）是一段可编码蛋白质的核苷酸序列，其间不存在任何终止编码的密码子。



原核基因识别任务的重点是识别开放阅读框。

基于基因密码子特性的识别方法

- 辨别编码区与非编码区的一种方法
 - 检查终止密码子的出现频率

遗传密码表

		第二位				
		U	C	A	G	
第一位 (5'端)	U	UUU } phe UUC UUA } leu UUG	UCU } UCC } ser UCA UCG	UAU } tyr UAC UAA } 终止 UAG } 终止	UGU } cys UGC UGA } 终止 UGG } trp	U C A G
	C	CUU } CUC } leu CUA CUG	CCU } CCC } pro CCA CCG	CAU } his CAC CAA } gln CAG	CGU } CGC } arg CGA CGG	U C A G
	A	AUU } AUC } ile AUA AUG 起始	ACU } ACC } thr ACA ACG	AAU } asn AAC AAA } lys AAG	AGU } ser AGC AGA } arg AGG	U C A G
	G	GUU } GUC } val GUA GUG	GCU } GCC } ala GCA GCG	GAU } asp GAC GAA } glu GAG	GGU } GGC } gly GGA GGG	U C A G

第三位 (3'端)

非编码区域:

如一条核酸序列是均匀随机分布的，那么终止密码子出现的期望次数为：

每21个 ($\approx 64/3$) 密码子出现一次终止密码子

编码区域:

绝大部分原核生物蛋白质的长度大于60个氨基酸
(*E. coli*: 蛋白质编码区域平均长度为316.8个密码子，
长度小于60个密码子的基因不到1.8%)


终止密码子频率

编码区域 << 非编码区域

【起始码 -> 终止码】距离

编码区域 >> 非编码区域

- 基本思想：
 - 如果能够找到一个比较长的序列，其相应的密码子序列不含终止密码子，则这段序列可能就是编码区域。



- 基本方法：
 - 扫描DNA序列，在三个不同的阅读框中寻找较长的ORF。遇到终止密码子以后，回头寻找起始密码子。

SOFTWARE: NCBI ORF Finder

ORF Finder (Open Reading Frame Finder)

Enter GI or ACCESSION


or sequence in FASTA format

FROM: TO:


[Genetic codes](#) ▼

<https://www.ncbi.nlm.nih.gov/orffinder/>

NCBI ORF Finder 分析实例



分析序列
GenBank:
L03845



改善原核基因预测方法

- 简单的**ORF Finder**只能正确地找到原核基因组大约85%的蛋白质编码区域，该算法过于简单，不适合于处理短的**ORF**。
- 在一些情况下不得不用更复杂的方法，比如**GeneMark**和**Glimmer**。这些情况包括：寻找很短的蛋白质；分析在不同的阅读框下有重合的**ORF**。
- 这些方法不是简单地找不间断的阅读框，同时考虑序列的统计特性计算每种可能**ORF**的概率。

当前著名的原核基因预测软件

1、GeneMark系列软件（包括最新版本GeneMarkS）

翻译起始位置预测准确率为83.2%-94.4%

——Besemer, J., Lomsadze, A. and Borodovsky, M. (2001) GeneMarkS: a self-training method for prediction of gene starts in microbial genomes. Implications for finding sequence motifs in regulatory regions. *Nucleic Acids Res.*, 29: 2607-2618.

2、Glimmer 2.02

基因识别的准确率约为97-98%

——Delcher, A. L., Harmon, D., Kasif, S., White, O., and Salzberg, S. L. (1999) Improved microbial gene identification with GLIMMER. *Nucleic Acids Res.*, 27, 4636-4641

分析举例（GeneMark）

- 1) GeneMark (<http://opal.biology.gatech.edu/GeneMark/>)
- 2) 选择适合原核生物基因识别程序
 - a) GeneMark-P 和GeneMark.hmm-P连用的预测程序
 - b) GeneMarkS预测程序
- 3) 提供需要预测分析的序列（GenBank:L03845），默认参数
- 4) 基因识别程序对提供的序列给出分析结果

分析举例 (GeneMark)

Gene Predictions in Text Format

Information on input sequence

Sequence title: L03845
Length: 2762 bp
G+C Content: 49.82 %

Parse predicted by GeneMark.hmm 2.4

GeneMark.hmm PROKARYOTIC (Version 2.6q)
Model organism: Escherichia_coli_K12
Sat Oct 11 04:05:22 2008

Predicted genes

Gene #	Strand	LeftEnd	RightEnd	Gene Length	Class
1	+	129	1910	1782	1
2	+	1923	2699	777	1

分析举例（Glimmer）

1) Glimmer 提供Glimmer的具体信息和最新版本的下载）
（http://www.ncbi.nlm.nih.gov/genomes/MICROBES/glimmer_3.cgi，提供在线预测服务）

2) 提供需要预测分析的序列（GenBank:L03845），并选择相关合适的参数（Genetic code: Bacteria; Topology: linear）

3) 基因识别程序对提供的序列给出分析结果

```
GLIMMER (ver. 3.02; iterated)  predictions:
  orfID      start      end  frame  score
  -----
>L03845
orf00002      39      1910   +3     3.00
orf00004     1923     2699   +3     6.02
```

GeneMark与Glimmer基因预测结果的比较

Parse predicted by GeneMark.hmm 2.4

Predicted genes

Gene #	Strand	LeftEnd	RightEnd	Gene Length
1	+	<u>129</u>	1910	1782
2	+	1923	2699	777

GLIMMER (ver. 3.02; iterated) predictions:

orfID	start	end	frame	score
-----	-----	-----	--	-----
>L03845				
orf00002	<u>39</u>	1910	+3	3.00
orf00004	1923	2699	+3	6.02


```
1 gatatcagca cggcgttggg actgaaagca catccataat gctgtgca tcccgtctg
61 cggagcgggt ttttttgaca aaatttgaaa gttggaaaaa tttccaata aatagaggta
121 ggaataaat ggcaaaaatg agagccgttg acgcggaat gtatgtgctg gagaaagaag
181 gtatcactac cgcttcggt gttccgggag ctgcaatcaa tccgttctac tcagcgatgc
```

真核基因识别

真核生物的基因结构——断裂基因结构

真核基因远比原核基因复杂：

- 真核生物的基因一般为**断裂基因**（interrupted gene），基因的编码序列在DNA上不是连续的，而是被不编码的序列隔开；
- 外显子（**exon**）：基因中编码的序列，与成熟mRNA的序列相对应。
- 内含子（**Intron**）：基因中不编码的序列。
- 真核基因具有丰富的调控信息。



真核生物的基因结构示意图

真核基因识别的主要方法

两大类识别方法：

- 基于同源序列比较的方法
 - 利用已知的基因编码信息（如mRNA或蛋白质序列），通过同源比较，在DNA序列中发现潜在的编码序列。
- 基于序列特征的方法
 - 根据DNA本身所具有的序列特征预测编码基因

理想的方法：综合两大类方法优点，开发混合算法。

基于同源序列比较的方法

通过相似性比对发现编码序列

DNA序列

EST, cDNA或蛋白质序列

DNA序列的某一片段与mRNA或蛋白质序列具有高度相似性，这说明该DNA片段极有可能是编码序列。


基于同源序列比较的方法

通过相似性比对发现编码序列

DNA序列

外显子

内含子



EST, cDNA或蛋白质序列

DNA序列的某一片段与mRNA或蛋白质序列具有高度相似性，这说明该DNA片段极有可能是编码序列。

基于同源序列比较的方法

- **BLAST**(最原始的方法，一般选用其子程序 **tBLASTn**和**BLASTx**进行分析，只能确定编码区的大致位置)
- **GeneWise**, **prosplan**, **sim4**等（具有剪接位点识别功能，所识别的内含子、外显子区域较准确）

BLAST

- (<http://blast.ncbi.nlm.nih.gov/Blast.cgi>)
 - 1) 提供需要分析的DNA序列
 - 2) 针对数据库选择适合的BLAST子程序
 - a) 对EST数据库中同一生物的cDNA序列进行比较分析（如Blastn）
 - b) 在6个阅读框中进行翻译并与蛋白质数据库中的序列进行比较分析（如Blastx）
 - 3) 确定基因数目和对应的ORF

GeneWise

- (<https://www.ebi.ac.uk/Tools/psa/genewise/>)
- 1) 输入需要分析的DNA序列，和蛋白序列（如D17291的蛋白和DNA序列）
 - 2) 选择参数
 - 3) 结果解读

>regenerating protein I beta

MAQTNSFFMLISSLMFLSLSQGQESQTELPNPRISCPEGTNAYRSYCYFNEPET
WVDADLYCQNMNSGNLVSVLTAEGAFVASLIKESSTDDSNVWIGLHDPKKNRRWH
WSSGSLVSYKSWDTGSPSSANAGYCASLTSCSGFKKWKDESCEKKFSFVCKFKN

基于序列特征的方法

一般意义上基因具有两种类型的特征

1. 找寻“信号”特征，由一些特殊的序列构成，通常预示着其周围存在着基因。
2. 比较“内容”特征，即蛋白质编码基因所具有的某些统计学特征。

基于序列特征的方法

- 序列特征信号
 1. 转录启动信号
 2. 起始密码子
 3. 外显子 剪接位点 (GT-AG法则)
 4. 终止密码子
 5. 转录终止信号 (包含多聚 A 序列)
 - 整个基因编码区长度一定是3的倍数


真核基因特征信号——转录启动区

启动子是一段特定的直接与RNA聚合酶及其转录因子相结合、决定基因转录起始与否的DNA序列。

TATA—box: 其一致顺序为TATAATAAT。约在基因转录起始点上游约-30-50bp处，基本上由A-T碱基对组成，是决定基因转录始的选择。

CAAT—box: 其一致顺序为GGGTCAATCT，是真核生物基因常有的调节区，位于转录起始点上游约-80-100bp处。

GC — box: 有两个拷贝，位于CAAT框的两侧，由GGCGGG组成。



真核基因特征信号——起始密码子

翻译起始位置：ATG



GCC**ATG**GCGA

ACG**ATG**CTGT

GAC**ATG**GTAC ...

AGG**ATG**GGCT ...

GCG**ATG**TGGC ...

并非所有的ATG都是起始密码子

真核基因特征信号——起始密码子

起始密码子两侧位置碱基的出现具有偏爱性





下面哪个序列更像翻译起始位置？

CACC ATG GCG

TTTT ATG TTA

真核基因特征信号——剪接位点

真核基因剪接（splicing）：从DNA模板转录的最初转录产物中除去内含子，并将外显子连接起来形成一个连续的RNA分子的过程。




卵清蛋白基因DNA与其mRNA杂交图


真核基因特征信号——剪接位点

- 外显子与内含子接头——“GT-AG法则”

外显子与内含子相连部位通常是一段高度保守的特定序列，即内含子5'端都是GT开始（供体位点），3'端都是AG结尾（受体位点），这种接头方式称为“GT-AG法则”。




RNA中对应剪接的信号为GU-AG




真核基因特征信号——终止密码子

终止密码子：TAA，TGA，TAG



真核基因特征信号——转录终止信号

转录终止子（**Terminator**）：由一段回文序列以及特定的序列**AATAAA**（或**ATTAAA**）组成。



序列特征信号

1.

2. 起始密码子

3. 外显子剪接位点 (GT-AG)

4. 终止密码子

5.

构建真核基因

tccatgcagaccatggcggtacaggacatgccggtgcagctctgactt



找到 起始密码和终止密码子

tccATGcagaccATGgcggtacaggacATGccggtgcagctcttgactt


找到 剪接位点

tccATGcagaccATGgcggtacaggacATGccggtgcagctcttgactt


构建真核4种基因外显子




起始外显子



单一外显子



中间外显子



终止外显子

tcc**ATG**cagacc**ATG**gcg**gt**ac**agg**ac**ATG**ccg**gt**gc**ag**ctc**tga**ctt



构建 可能的外
显子

- 1 **ATG**cagaccATGgcg
- 2 **ATG**cagaccATGgcg**gt**acaggacATGccg
- 3 **ATG**cagaccATGgcg**gt**acaggacATGccg**gt**gcagctc**tga**
- 4 accATGgcg
- 5 accATGgcg**gt**acaggacATGccg
- 6 accATGgcg**gt**acaggacATGccg**gt**gcagctc**tga**
- 7 **ATG**gcg
- 8 **ATG**gcg**gt**acaggacATGccg
- 9 **ATG**gcg**gt**acaggacATGccg**gt**gcagctc**tga**
- 10 gacATGccg
- 11 gacATGccg**gt**gcagctc**tga**
- 12 **ATG**ccg
- 13 **ATG**ccg**gt**gcagctc**tga**
- 14 ctc**tga**

哪个最优解?

基于序列特征的分析编码潜力

- 编码序列统计学特征
 - 密码子使用偏爱性
 - 双联密码子出现频率

密码子使用偏爱性

密码子**简并性**: 同一种氨基酸具有两个或更多个密码子编码的现象。

密码子**偏爱性**: 兼并密码子的使用频率并不均等, 各种生物编码某种氨基酸往往较多地采用其中一种。

遗 传 密 码 表

		第二 位					
		U	C	A	G		
第一 位 (5' 端)	U	UUU } phe UUC } UUA } leu UUG }	UCU } UCC } ser UCA } UCG }	UAU } tyr UAC } UAA 终止 UAG 终止	UGU } cys UGC } UGA 终止 UGG trp	U C A G	第三 位 (3' 端)
	C	CUU } CUC } leu CUA } CUG }	CCU } CCC } pro CCA } CCG }	CAU } his CAC } CAA } gln CAG }	CGU } CGC } arg CGA } CGG }	U C A G	
	A	AUU } AUC } ile AUA } AUG 起始	ACU } ACC } thr ACA } ACG }	AAU } asn AAC } AAA } lys AAG }	AGU } ser AGC } AGA } arg AGG }	U C A G	
	G	GUU } GUC } val GUA } GUG }	GCU } GCC } ala GCA } GCG }	GAU } asp GAC } GAA } glu GAG }	GGU } GGC } gly GGA } GGG }	U C A G	

密码子使用偏爱性

利用密码子使用频率对序列进行分析可以发现编码区的粗略位置。

	U		C		A		G	
U	UUU Phe	57	UCU Ser	16	UAU Tyr	58	UGU Cys	45
	UUC Phe	43	UCC Ser	15	UAC Tyr	42	UGC Cys	55
	UUA Leu	13	UCA Ser	13	UAA Stp	62	UGA Stp	30
	UUG Leu	13	UCG Ser	15	UAG Stp	8	UGG Trp	100
C	CUU Leu	11	CCU Pro	17	CAU His	57	CGU Arg	37
	CUC Leu	10	CCC Pro	17	CAC His	43	CGC Arg	38
	CUA Leu	4	CCA Pro	20	CAA Gln	45	CGA Arg	7
	CUG Leu	49	CCG Pro	51	CAG Gln	66	CGG Arg	10
A	AUU Ile	50	ACU Thr	18	AAU Asn	46	AGU Ser	15
	AUC Ile	41	ACC Thr	42	AAC Asn	54	AGC Ser	26
	AUA Ile	9	ACA Thr	15	AAA Lys	75	AGA Arg	5
	AUG Met	100	ACG Thr	26	AAG Lys	25	AGG Arg	3
G	GUU Val	27	GCU Ala	17	GAU Asp	63	GGU Gly	34
	GUC Val	21	GCC Ala	27	GAC Asp	37	GGC Gly	39
	GUA Val	16	GCA Ala	22	GAA Glu	68	GGA Gly	12
	GUG Val	36	GCG Ala	34	GAG Glu	32	GGG Gly	15

阅读框出现偏爱密码子，则该阅读框比较有可能是编码序列。

人类基因组密码子使用频率表

双联密码子出现频率

在实际应用中更多的是使用二联密码子出现频率

Name	ala	arg	asn	asp	cys	glu	gln	gly	his	ile	leu	lys	met	phe	pro	ser	thr	trp	tyr	val
ala	9.5	4.1	4.3	5.3	1.2	6	4.8	6.5	2	6.5	11.5	6	2.6	3.7	3.5	6.2	5	1.1	2.7	6.5
arg	7.9	5.5	3.9	5.3	1.1	6	5.5	5.9	2.6	6.5	11.4	5	2.2	4.7	3.6	5.5	4.4	1.4	4	6.6
asn	9.6	4.9	4.2	4.9	1	5.3	5.6	7.4	2.3	6	10	4.9	2	3.5	5.1	6.1	5.5	1.5	3.1	6.1
asp	9.3	4	4.7	5.1	1	6.7	2.9	7	1.8	7.1	9.6	6.3	2.3	4.3	3.9	5.9	5.1	1.6	3.6	6.6
cys	8.4	4.8	3.3	5.4	1.7	5.6	5.2	8.1	4.3	5.4	10.2	3.8	1.8	4.1	4.5	6.3	4.3	1.6	3.4	6.8
glu	9.4	5.8	3.6	4.5	0.8	4.9	7	5.8	2.6	5.9	12.7	5	2.4	4	3.5	5.4	5	1.1	2.8	6.8
gln	10.3	4.9	3	4.4	0.9	4.5	6.8	7	2.7	5.5	12.8	4.1	2	3.9	3.8	5.8	5.3	1.4	3	6.9
gly	8.1	4.8	3.9	5.1	1.2	6	4.6	6.4	2.4	6.8	10.5	5.8	2.7	4.8	2.4	5.8	5.1	1.4	3.7	7.5
his	7.3	4.7	4	4.8	1.5	4.9	5.6	6.9	3	6.2	10.8	4.8	1.6	5	5.2	6.8	4.9	1.7	4.2	5.1
ile	11	4.7	4.9	6.5	1.1	6.9	3.6	7.2	2.1	5.3	8.6	5.3	1.8	3.2	4.2	7	5.6	0.9	2.9	6.1
leu	10.4	4.2	4.3	5.2	1.1	5.2	3.7	6.8	2	5.6	10.6	5.3	2.3	3.8	4.5	7.4	6.2	1	2.6	6.6
lys	10.6	5.2	3.8	5.2	0.5	5.3	5.9	6.6	2.6	5.2	11.3	4.7	1.9	2.8	4.6	6	5.5	1.2	2.6	7.6
met	10.8	4.8	3.8	4.6	0.7	4.6	4.9	7	1.7	4.7	11.4	5.2	2.8	3.3	5.1	7.4	6.3	0.9	2	6.8
phe	9.6	3.7	5.2	6.5	1.2	6.4	2.7	7.9	1.9	6.7	7.4	5	2.5	3.9	3.6	8	5.8	1.3	3.3	6.3
pro	8.4	3.6	4.6	5.4	0.7	7.6	5.2	5.4	2.3	6.1	11.2	5.5	2.4	4.2	2.8	6.5	5.4	1.4	2.9	7.5
ser	9.1	4.6	3.7	5	1	5.4	5.2	7.2	2.6	6	11.6	4.5	2.2	4.1	4.1	6.5	5	1.2	3.2	6.8
thr	9.1	4.2	3.7	5.6	0.9	5.7	5.7	7.5	2.2	5.5	12	4.2	2	3.5	5.5	6.2	5.3	1.1	2.6	6.7
trp	7.1	6.3	3.2	4.8	1.3	3.9	8.5	6.6	3.6	5	14.2	3.2	2.4	4.6	3.9	5.8	4.3	1.3	3	6.1
tyr	7.9	6.5	3.6	4.9	1.2	4.5	7	7.1	2.6	5	11.7	4	1.6	4.7	4.9	6.4	4.6	1.5	3.4	5.7
val	9.6	4.1	4.4	5.9	1	6.2	3.4	6.4	1.8	6.5	10.2	5.2	2.5	3.7	3.8	7.2	6.1	1.1	2.7	7.1

有些二联密码子（亮氨酸与色氨酸）倾向于同时出现，另一些（脯氨酸与半胱氨酸）则不是

tcc**ATG**cagacc**ATG**gcg**gt**ac**agg**ac**ATG**ccg**gt**gc**ag**ctc**tga**ctt



可能的外显子的编码潜力


- 1 **ATG**cagacc**ATG**gcg
- 2 **ATG**cagacc**ATG**gcg**gt**ac**agg**ac**ATG**ccg
- 3 **ATG**cagacc**ATG**gcg**gt**ac**agg**ac**ATG**ccg**gt**gc**ag**ctc**tga**
- 4 acc**ATG**gcg
- 5 acc**ATG**gcg**gt**ac**agg**ac**ATG**ccg
- 6 acc**ATG**gcg**gt**ac**agg**ac**ATG**ccg**gt**gc**ag**ctc**tga**
- 7 **ATG**gcg
- 8 **ATG**gcg**gt**ac**agg**ac**ATG**ccg
- 9 **ATG**gcg**gt**ac**agg**ac**ATG**ccg**gt**gc**ag**ctc**tga**
- 10 gac**ATG**ccg
- 11 gac**ATG**ccg**gt**gc**ag**ctc**tga**
- 12 **ATG**ccg
- 13 **ATG**ccg**gt**gc**ag**ctc**tga**
- 14 ctc**tga**

构建最优真核基因结构

基因组装

构建最优真核基因结构

tcc**ATG**c**ag**acc**ATG**gcg**gt**ac**ag**gac**ATG**ccg**gt**gc**ag**ctct**ga**ctt




→
可能的外显子

- - - - ->
可能的内含子

从起点到终点的任何一条路径代表一个可能的基因结构


构建最优真核基因结构

根据编码区序列统计学特性确定可能外显子的概率大小




构建最优真核基因结构

根据外显子的概率大小确定可能的基因结构



构建真核基因模型

tcc**ATG**cagacc**ATG**gcggtacaggac**ATG**ccggtgcagctctga**ctt**



tcc**ATG**cagaccatggcggtacaggacatgccggtgcagctctga**ctt**

外显子1


内含子

外显子2

ATGcagaccatggcgctctga

ORF

基因识别的过程



常用真核基因预测软件

(1)、FGENEH

所用算法：线性判别分析（**Linear Discriminant Analysis**）方法

(2)、GeneID

所用算法：法则系统（**Rule-based System**）算法

(3)、GeneParser

所用算法：动态规划算法（**Dynamic Programming**）

(4)、GRAIL

所用算法：人工神经网络方法

(5)、MZEF

所用算法：决策树（**decision tree**）方法

(6)、GENSCAN

所用算法：隐Markov模型（**Hidden Markov Model**）方法、动态规划算法

(7)、Genie

所用算法：广义隐Markov模型（**Generalized Hidden Markov Model**）方法、动态规划算法

(8)、HMMgene

所用算法：隐Markov模型（**Hidden Markov Model**）方法

基因识别程序性能比较

程序	预测类型	敏感性 (1)	特异性 (1)	敏感性 (2)	特异性 (2)	未找到的 外显子	找 错 的 外显子
FGFTEH	基因结构	83	93	73	78	15	11
GeneID	基因结构	69	77	42	46	28	24
GeneParser	基因结构	66	79	35	40	29	17
Genie	基因结构	87	88	69	70	10	15
GenLang	基因结构	72	79	51	52	21	21
GENSCAN	基因结构	93	93	78	81	9	5
GRAIL D	内部外显子	79	85	51	57	25	28
GRAIL D /GAP	基因结构	83	87	-	52	25	10
HEXON	内部外显子	88	80	71	65	10	27
MORGAN	基因结构	83	79	58	51	14	-
NIFF	内部外显子	87	95	78	86	14	7
SorFind	内部外显子	71	85	42	47	24	14
VEIL	基因结构	83	72	53	49	19	-
Xpound	内部外显子	61	87	15	18	32	13

敏感性(1)—被预测出的真实编码核酸（%）；

敏感性(2)—被正确识别出的编码外显子（%）；

特异性(1)—预测出的编码核酸为真实编码核酸（%）；

特异性(2)—预测出外显子为真实外显子（%）

分析举例（Genscan）

- Genscan (<http://genes.mit.edu/GENSCAN.html>)
- 2) 选择适合物种模式物种作为参照
 - a) Vertebrate
 - b) **Arabidopsis**
 - c) Maize
- 3) 提供需要预测分析的序列（**GenBank:AB363664**），并选择相关合适的参数（默认参数）
- 4) 基因识别程序对提供的序列给出分析结果

分析举例 (Genscan)

GENSCAN 1.0

Date run: 11-Oct-108

Time: 20:03:18

Sequence gi : 5500 bp : 38.56% C+G : Isochore 1 (0 - 43 C+G%)

Parameter matrix: Arabidopsis.smat

Predicted genes/exons:

Gn.Ex	Type	S	.Begin	...End	.Len	Fr	Ph	I/Ac	Do/I	CodRg	P....	Iscr..
1.01	Init	+	1091	1260	170	1	2	72	-23	253	0.990	16.65
1.02	Intr	+	1383	1500	118	0	1	-40	76	104	0.951	0.95
1.03	Intr	+	1696	2280	585	0	0	17	-19	378	0.311	16.92
1.04	Intr	+	2367	2468	102	2	0	102	76	56	0.998	10.25
1.05	Intr	+	2560	2763	204	0	0	25	32	145	0.631	6.07
1.06	Intr	+	3035	3206	172	1	1	32	67	140	0.980	9.89
1.07	Intr	+	3257	3487	231	0	0	55	93	312	0.944	30.22
1.08	Intr	+	3539	3687	149	0	2	65	62	76	0.898	6.73
1.09	Term	+	3776	4117	342	1	0	29	41	282	0.948	16.13
1.10	PlyA	+	4149	4154	6							-4.04
2.03	PlyA	-	4217	4212	6							-0.45
2.02	Term	-	4845	4576	270	0	0	37	34	269	0.976	15.90
2.01	Intr	-	5451	5009	443	1	2	41	74	204	0.660	11.55

Explanation

Gn.Ex : gene number, exon number (for reference)

Type : Init = Initial exon (ATG to 5' splice site)

Intr = Internal exon (3' splice site to 5' splice site)

Term = Terminal exon (3' splice site to stop codon)

Sngl = Single-exon gene (ATG to stop)

Prom = Promoter (TATA box / initiation site)

PlyA = poly-A signal (consensus: AATAAA)

S : DNA strand (+ = input strand; - = opposite strand)

Begin : beginning of exon or signal (numbered on input strand)

End : end point of exon or signal (numbered on input strand)

Len : length of exon or signal (bp)

Fr : reading frame (a forward strand codon ending at x has frame $x \bmod 3$)

Ph : net phase of exon (exon length modulo 3)

I/Ac : initiation signal or 3' splice site score (tenth bit units)

Do/T : 5' splice site or termination signal score (tenth bit units)

CodRg : coding region score (tenth bit units)

P : probability of exon (sum over all parses containing exon)


Tscr : exon score (depends on length, I/Ac, Do/T and CodRg scores)

Comments

- The **SCORE** of a predicted feature (e.g., exon or splice site) is a log-odds measure of the quality of the feature based on local sequence properties. For example, a predicted 5' splice site with score > 100 is strong; 50-100 is moderate; 0-50 is weak; and below 0 is poor (more than likely not a real donor site).
- The **PROBABILITY** of a predicted exon is the estimated probability under GENSCAN's model of genomic sequence structure that the exon is correct. This probability depends in general on global as well as local sequence properties, e.g., it depends on how well the exon fits with neighboring exons. It has been shown that predicted exons with higher probabilities are more likely to be correct than those with lower probabilities.

分析举例（Genscan）

GENSCAN predicted genes in sequence



Key:



Initial
exon



Internal
exon



Terminal
exon



Single-exon
gene



Optimal exon



Suboptimal exon

分析举例（MZEF）

- MZEF (<http://rulai.cshl.org/tools/genefinder/>)

2) 选择要预测的物种基因组序列

a) Human

b) Mouse

c) **Arabidopsis**

d) Fission Yeast

3) 提供需要预测分析的序列（**GenBank:AB363664**），并选择相关合适的参数（**Prior Probability: 0.05**）

4) 基因识别程序对提供的序列给出分析结果

分析举例 (MZEF)

MZEF Results - arabidopsis
Sat Oct 11 20:24:15 2008


Strand = 1
Overlap = 0
Prior Prob. = .05

Internal coding exons predicted by MZEF

File_Name: zef1_seq91 Sequence_length: 5500 G+C_content: 0.386

Coordinates	P	Fr1	Fr2	Fr3	Orf	3ss	Cds	5ss
1383 - 1500	0.953	0.634	0.598	0.460	112	0.502	0.612	0.683
1696 - 2280	0.579	0.586	0.481	0.455	122	0.560	0.568	0.609
2367 - 2468	1.000	0.482	0.551	0.615	221	0.749	0.596	0.772
2560 - 2753	0.979	0.548	0.514	0.565	122	0.628	0.592	0.672
3035 - 3206	0.998	0.570	0.589	0.530	212	0.695	0.619	0.641
3320 - 3687	0.729	0.618	0.441	0.536	122	0.619	0.591	0.457

MZEF、Genscan基因预测与已注释结果的比较




Key:  Initial exon  Internal exon  Terminal exon  Single-exon gene

■ 已注释外显子
■ MZEF预测的外显子
■ Genscan预测的外显子

综合多个方法提高预测的准确性

- 目前还没有一个基因预测工具可以完全正确地预测一个基因组中的所有基因 (Mathe C, Sagot MF, Schiex T, Rouze P. 2002. Current methods of gene prediction, their strengths and weaknesses. Nucleic Acids Res. 30:4103-4117)
- 目前最好的基因预测工具预测一个基因组中的所有外显子的准确率最多达到75%，预测基因结构的准确率< 50%
(Rogic S, Ouellette BF, Mackworth AK. 2002. Improving gene recognition accuracy by combining predictions from two gene-finding programs. Bioinformatics. 18:1034-1045)
- 不同的基因预测软件分析结果有差异
- 综合多个基因预测软件的分析结果

综合多个方法提高预测的准确性



Ensembl注释系统所分析的人类基因结构的详情